FICHE DE RÉVISION · 1ER MIDTERM · 2026-10-26

Ethics of AI, cours 01 à 05

Résumé des slides AIE2026-01 à 05 (132 pages, export Moodle du 2026-10-15). Les termes à réutiliser en anglais dans la copie sont en couleur. Ce qui ne vient pas des slides est marqué « rappel général ». Format du midterm : non publié.

Slides 132 p. Cours 5 Auteur des slides M. Héder Seuil 50 % par contrôle

REPRIS 3 FOIS

Responsibility gap

Cours 01, 02 et 05. Le thème le plus répété du bloc.

REPRIS 2 FOIS

Axiology of action

Cours 01 et 05 : valeur marchande, inhérente, instrumentale.

REPRIS 2 FOIS

Moral inclusion of AI

Cours 03 et 04 : prothèse cérébrale, origine contre fonction, premise bingo.

AIE-01 · 34 P. · INTRODUCTION

Identité, valeur du travail, lock-in technologique

> L'IA touche ce qui fonde notre identité (le métier, les relations) et risque de se figer avant qu'on ait compris ses problèmes. Réponses proposées : la conception centrée sur l'humain et l'éthique des machines. Limite : la responsabilité ne se délègue pas.

ACCROCHE

Ton partenaire a une relation amoureuse avec une app d'IA : LLM haut de gamme, 100 EUR par mois, mémoire à vie tant qu'on paie, passe le test de Turing. Il dit « être amoureux ». `Is this cheating on you?`

IDENTITÉ

- `Analytic approach` : définir le tout par ses parties. Exige une mesure de similarité (bateau de Thésée), problèmes partout.
- `Narrative autobiography` (Schechtman, 2007) : l'identité repose sur des caractéristiques : partenaire, parent, supporter d'un club, professionnel.
- Une caractéristique forme l'identité si elle est plutôt `permanent`, donne une `conviviality with a community`, et a de la valeur pour la personne.
- L'identité professionnelle est une identité publique. Nouveau défi : l'IA. Exemple des slides : le sort de l'illustrateur.

AXIOLOGIE

`Axiology of action` (Schroeder, Stanford Encyclopedia, 2024) : la valeur d'une action pour un individu se lit sur plusieurs axes : `market value`, `inherent value`, `instrumental value`, `cultural obligations`.

Activités placées sur le schéma : dire un poème, collectionner des cartes postales, dessiner, éduquer, copywriting, programmer, servir à table, porter secours, lacer ses chaussures, dire bonjour, faire le ménage. Le schéma est montré deux fois avec une disposition différente.

LOCK-IN

`QWERTY` : Sholes, premier clavier de machine à écrire (années 1860). La machine s'enrayait si on tapait vite : Sholes passe de l'ordre alphabétique à QWERTY pour ralentir l'utilisateur. Plusieurs dispositions coexistent dans les années 1880 ; en 1890, plus aucune raison technique. Remington l'achète et le diffuse comme « universal ».

Trois causes du verrouillage : `economies of scale`, `interdependence of technology`, `irredeemable investments`.

COLLINGRIDGE

`Collingridge dilemma` : une technologie neuve est facile à modifier, mais on manque d'information pour voir ses problèmes. Une fois établie et omniprésente, les problèmes sont visibles, mais la changer est difficile. Exemple : le DDT.

POURQUOI L'IA

- Impact plus grand : de moins en moins de propriétaires de la technologie influencent une part de plus en plus grande du monde.
- L'IA est du logiciel : coût marginal de copie négligeable. Un bon système de diagnostic, psychologue ou comptable sera copié plutôt que réécrit.
- Software-as-a-Service : fourni de n'importe où (sauf les robots contrôlés localement).
- Les directions prises au départ seront difficiles à changer. Exemple : les comptes Gmail.

HUMAN-CENTERED DESIGN

Contre-exemples : le travail des enfants pendant la révolution industrielle, le chronocyclographe de Gilbreth (organisation scientifique du travail).

Trois stratégies d'auto-absolution du fabricant : `the imperative of technology`, `this is what the customer wants`, `this is what efficiency dictates`, plus « c'était légal à l'époque ». Le human-centered design les rejette toutes, avec les outils des humanités (argumentation, esprit critique) et la connaissance des humains (Humanscale, Henry Dreyfuss Associates, 1974).

MACHINE ETHICS

Concevoir le comportement d'une personne artificielle. On lui donne de l'autonomie justement pour qu'elle décide à notre place (analogie : élever des enfants). On veut éviter biais et opacité. On la place dans une position de confiance sans précédent, et elle peut développer ses propres buts.

SUJET	CONTENU
`Transparency`	Explicabilité
`Fairness`	Biais, absence de discrimination
`Alignment`	Valeurs sociales larges comme le bien-être : fait entrer la politique

`Fairness metrics` : `Equal Opportunity` exige $TPR_0 \approx TPR_1$. `Equalized Odds` exige en plus $FPR_0 \approx FPR_1$.

RESPONSIBILITY GAP

Matthias (2004), Champagne et Tonkens (2015). Le « procès de la voiture » : on peut déléguer des décisions à l'IA, beaucoup moins la responsabilité (pas impensable, mais socialement irréaliste). Un écart se crée, la tension monte. Il faut de la responsabilité même si l'IA dépasse les professionnels, comme l'architecte qui a une `liability insurance`. Nouvel équilibre : `professional + AI`.

AIE-02 · 18 P. · INTRODUCTION 2

Responsabilité, décision et opacité

> Une IA peut agir et décider, mais pas répondre de ses actes. Le cours situe où les décisions morales sont réellement prises (à la conception, pas à l'exécution) et pourquoi un système autonome reste opaque. Il se termine par la carte du domaine.

RESPONSIBILITY GAP

On peut déléguer les décisions, on peut déléguer les actions, on ne peut pas déléguer l'`accountability`. D'où l'écart. Expérience de pensée de P. Lin, reprise dans Héder, *The epistemic opacity of autonomous systems and the ethical consequences*, AI & Society (2020).

DESIGN-TIME / RUNTIME

Exemple des véhicules autonomes. Ce qui est souhaitable : une répartition fluide du « travail de responsabilité » entre les humains qui restent dans la boucle.

Chaîne de vie d'une technologie : R&D, développement, conception, production, exploitation (brevet, savoir de conception, plan ou norme, savoir-faire de fabrication, artefact déployé, usage et maintenance). Comme on considère que l'IA n'est pas un agent moral, `no moral decisions allowed in run-time` : les choix moraux sont faits en amont, à la conception. Test proposé : la punition des machines.

EPISTEMIC OPACITY

La représentation du problème rencontre la `underdetermination`. Les alternatives entre lesquelles l'agent choisit dépendent de sa compréhension de la situation, et améliorer cette compréhension consomme les mêmes ressources et le même temps que l'action elle-même. Les slides illustrent par trois expériences de pensée « old advice » (images seules).

DÉCIDER DE DÉCIDER

Il faut décider du moment où l'on décide (`point-of-decision`), ce qui donne une portée éthique à l'architecture de l'agent : boucle de rétroaction, `OODA`, holisme (pas de séparation des préoccupations), évaluation de la décision.

Rappel général : OODA signifie Observe, Orient, Decide, Act.

DISCOVERY / ML

Chercher un savoir généralisable peut devenir une obligation morale, puisque le réutiliser ne coûte rien. Le machine learning peut aussi devenir une obligation morale, mais il réduit la transparence.

CARTE DU DOMAINE

BRANCHE	QUESTIONS
`Machine ethics`	Comment développer une IA éthique : éviter le lock-in des biais, transparence, `meaningful human oversight`
`Artificial person`	Droits des robots, hybrides humain-machine, statut moral de l'IA
`Social consequences`	Marché du travail, révolution industrielle et troubles sociaux, IA à l'université, bulle de filtre, régulation
`Extra`	Protection des données, questions environnementales

AIE-03 · 23 P. · PHILOSOPHIE DE L'ESPRIT

Conscience, esprit et test de Turing

> Pour savoir si une IA mérite une considération morale, il faut savoir si elle peut avoir un esprit. Le cours passe en revue les théories de l'esprit et montre que la réponse dépend des prémisses qu'on accepte, et en partie de la culture.

PROTHÈSE CÉRÉBRALE

`Brain prosthesis thought experiment` (slide en image seule). Si la `multiple realization` s'applique à l'esprit : conscience éternelle, sauvegardes et copies (`mind-fork`), auto-édition de l'esprit, édition de la mémoire (Total Recall), esprits entièrement nouveaux. Les réseaux de neurones artificiels seraient peut-être des esprits.

Rappel général : on remplace un à un les neurones d'un cerveau par des composants artificiels de fonction identique. À quel moment, s'il y en a un, la conscience disparaît-elle ?

INCLUSION MORALE 1

Considérer l'IA si elle remplit l'exigence dure d'un cadre éthique accepté : conscience, rationalité, libre arbitre. En utilitarisme (choisir l'action qui minimise la souffrance ou maximise le bonheur), on a d'abord inclus les animaux parce qu'ils peuvent souffrir. Si les machines remplissent aussi cette exigence… (film : Bicentennial Man, avec Robin Williams).

CONSCIENCE

Définition (Graziano, *What is consciousness?*, 2019) : `the mind's oversight of its own functioning`. À ne pas confondre avec l'intelligence : nous avons beaucoup de compétences intelligentes inconscientes. Exemple des slides : la perte de vision d'un seul côté.

THÉORIES

POSITION	THÈSE	POINT FAIBLE OU CONSÉQUENCE
Interactionism	Dualisme : âme et matière agissent causalement l'une sur l'autre	Le monde physique n'est pas causalement complet
Epiphenomenalism	Dualisme : le mental est un effet secondaire du physique	L'esprit ne cause rien
Parallelism	Dualisme : aucune interaction entre les deux mondes	Pourquoi restent-ils synchronisés ?
Idealism	Monisme : seul le mental existe, le monde extérieur est une illusion	Argument : on vit l'esprit directement, le monde indirectement
Behaviorism	Monisme physicaliste	Pas détaillé dans les slides
Identity theory	Un état mental est identique à l'état physique qui le réalise	Incompatible avec la réalisation multiple
Functionalism	Ce qui fonctionne comme un état mental est cet état mental. Un neurone artificiel qui fait le travail du neurone suffit	Physical Symbol System Hypothesis : position fonctionnaliste
Emergence	Troisième voie entre dualisme et monisme	Pas détaillé dans les slides

TEST DE TURING

- `Imitation game` : un juge humain converse par chat avec une machine et un humain, qui veulent tous deux le convaincre qu'ils sont humains. Si la machine gagne, elle pense.
- Prédiction de Turing (1950) : en 2000, une machine trompera 30 % des juges après 5 minutes. Atteint en 2014 par « Eugene Goostman » (garçon ukrainien de 13 ans). Selon les slides, `comprehensively passed in 2024`.
- Pour Turing, comptent les capacités, pas l'implémentation. On ne peut pas exiger plus d'un agent intelligent qu'un comportement intelligent. Discriminer sur le mode de fonctionnement serait un préjugé.

ORIGINE / FONCTION

Une bouteille de vin de 1809 vaut par son origine : une copie parfaite du liquide vaudrait beaucoup moins. L'insuline vaut par sa fonction : la synthétique peut même être meilleure. Ce qui compte, origine ou fonction, est largement culturel. La valeur des systèmes intelligents sera donc probablement tranchée culturellement. Exemple des slides : les peintures d'AARON.

Rappel général : AARON est un programme de peinture développé par l'artiste Harold Cohen.

PREMISE BINGO

SI ON VEUT CROIRE QUE…	…ALORS ON EXCLUT
le monde physique est causalement clos	Dualisme interactionniste, idéalisme
l'esprit cause nos actions	Épiphénoménisme, parallélisme
l'esprit reste le même malgré le renouvellement des composants du cerveau	Théorie de l'identité stricte

Ordre des deux premières lignes reconstitué : le texte extrait de la slide est désordonné. La logique est cohérente avec le tableau des théories.

AIE-04 · 22 P. · MORAL CONSIDERATION

Des chiens cartésiens aux droits de l'IA

> Les animaux sont passés de « machines sans douleur » à êtres moralement considérés, sans expérience décisive. La même transition peut arriver à l'IA, et il existe au moins cinq raisons distinctes de lui accorder une considération morale.

PRÉCÉDENT

Traitement des chiens dans les cercles cartésiens des années 1660 (Olson, 1990). Nicolas Malebranche (1638 à 1715), mécaniste néo-cartésien : pour des raisons religieuses, les animaux n'ont pas d'âme, ne souffrent pas, et sont donc hors de toute considération morale.

GROUPE	PROFIL SELON LES SLIDES
Common people	Pas d'éducation universitaire, pas de métaphysique, croient ce qu'ils voient, problèmes quotidiens
Elite	Très éduqués, comprennent le dualisme cartésien, « voient au-delà de la surface », questions fondamentales

La même carte est ensuite reprise pour l'IA : `everyday people` d'un côté, `some parts of the elite` de l'autre.

OBSERVATIONS

- La transition vers la considération morale des animaux s'est faite sans expérience cruciale sur les animaux.
- Un nouveau mode de considération morale a été créé.
- La transition n'est sans doute pas terminée (débat sur la consommation de viande).
- Question du cours : `can a similar transition to moral status happen to AI?`

5 POSITIONS

N°	ON CONSIDÈRE L'IA…	ARGUMENT OU ANALOGIE
1	si elle remplit l'exigence dure d'un cadre éthique (conscience, rationalité, libre arbitre)	Les animaux en utilitarisme, parce qu'ils souffrent
2	si son rôle dans un système plus large est critique	Protection de l'environnement : on protège des plantes menacées sans les croire conscientes. Sur une station spatiale, maltraiter une IA pourrait être puni comme cueillir un perce-neige protégé
3	pour son rôle dans les relations sociales	Assistant familial : la famille est le système. Film : Robot and Frank
4	pour éviter des effets psychologiques négatifs	Ne pas respecter un être humanoïde nous entraîne à déshumaniser. Mieux vaut le respecter, même par excès
5	à la demande d'autres humains	Un proche, un groupe militant ou un parti l'exige : on respecte par égard pour eux. Analogie : abolition de l'esclavage, émancipation des femmes. Série : Battlestar Galactica

REPRIS DU 03	Inclusion morale 1, prothèse cérébrale, origine contre fonction, premise bingo : mêmes slides que le cours 03. REPRIS

AIE-05 · 35 P. · FUTURE OF LABOR

L'IA et l'avenir de ton travail

> L'IA automatise des tâches plutôt que des métiers. Le risque principal touche les débutants, et à travers eux la formation des futurs experts. Ce qui restera aux humains : la responsabilité et l'accountability, qui deviennent un marché et peut-être un pilier de l'identité professionnelle.

QUESTION

Entre ton diplôme et la fin de ta carrière (+50 ans) : `what will you do that will make sense and possibly be worth a wage?`

OPTION	CONTENU	PROBLÈME
1. Rien	Débat sur le revenu universel	Effets néfastes possibles sur l'identité
2. Moins cher	Ce que l'IA ne fait pas moins cher que toi	Existe-t-il quelque chose ? Circulaire si l'IA rend ton travail moins cher
3. Impossible	Ce que l'IA ne sait pas faire, en succès performatif	Le succès phénoménologique est hors sujet. Voir les débats « machines cannot do X »
4. Interdit	Ce que l'IA ne sera pas autorisée à faire	Recoupe l'option 3 : elle sait le faire, mais pas de façon responsable ou assez bien

DISRUPTION

`Disruptive innovation` (Christensen et al., 2015) : l'acteur en place est `Homo sapiens`, le nouvel entrant est l'IA. Développement très rapide (exemple : traduction automatique).

Croix de Marshall (offre et demande, Alfred Marshall, 1842 à 1924), appliquée au marché « draw me an illustration », puis au marché de la `human oversight and accountability`.

Rappel général : si l'offre d'illustrations explose, le prix d'équilibre baisse. Les graphes des slides n'ont pas de légende textuelle.

MÉCANISMES

L'IA agit sur le marché du travail par six mécanismes : elle automatise des tâches, assiste les travailleurs, crée des tâches et des métiers, change les compétences requises, change le recrutement et le management, redistribue revenus et pouvoir de négociation entre travailleurs, entreprises et propriétaires de la technologie.

OIT : la `transformation` des métiers est plus probable que leur remplacement complet, car un métier regroupe plusieurs tâches dont seules certaines sont exposées à l'IA générative.

5 DIMENSIONS

DIMENSION	CONTENU
Job quantity	Emplois créés, supprimés ou non pourvus
Job content	Tâches effectuées dans un métier
Job quality	Autonomie, intensité, sécurité, sens, conditions de travail
Distribution	Partage des salaires, profits, gains de productivité et risques
Institutions	Recrutement, éducation, formation, management, négociation collective, protection sociale

OCDE : les premiers effets se voient plus dans la qualité de l'emploi et l'organisation du travail que dans le nombre d'emplois.

TÂCHES

`Jobs are bundles of tasks` : une technologie automatise des tâches, pas des métiers entiers. Un enseignant prépare des cours, explique, évalue, motive, gère les conflits, repère les situations de détresse, communique avec les parents. L'IA peut aider à préparer un cours sans automatiser le métier.

`Displacement effect` : la technologie remplace le travail sur une tâche. `Reinstatement effect` : de nouvelles tâches sont créées. La hausse de productivité peut aussi augmenter la production et la demande de travail complémentaire.

Cas du génie logiciel : tableau des rôles (junior, ingénieur exigences, medior, senior, architecte) croisés avec les phases (conception, construction, test, exploitation, maintenance, configuration, qualité, sécurité), cotés de « unchanged » à « disruption ». Le contenu des cases n'est pas lisible dans le texte extrait.

DÉBUTANTS

Les tâches des juniors sont routinières, standardisées, faciles à évaluer, riches en documentation, donc adaptées à l'IA : recherche documentaire simple, premiers jets, programmation simple ou moyenne, revue de documents, saisie, support client courant, administratif. Les seniors y ajoutent savoir tacite, accountability, relation client, mémoire de l'organisation, jugement stratégique, encadrement.

Une organisation peut garder ses seniors équipés d'IA et recruter moins de juniors. Stanford : baisse relative de l'emploi des 22 à 25 ans dans les métiers très exposés, emploi plus stable pour les plus expérimentés.

`Training-pipeline problem` : les tâches de débutant produisent un résultat et forment au métier. Les automatiser donne de la productivité à court terme mais affaiblit la formation des futurs experts. Exemple : les jeunes avocats apprennent par la recherche de cas, la rédaction d'actes standard et les corrections des seniors.

EXPÉRIENCES

- **Programmation** : script qui forme des équipes de 3 à 4 sur 4 tours sans jamais remettre deux personnes ensemble (50 à 150 étudiants, sortie en 4 CSV). Tests non publiés, une seule chance. Les enjeux élevés forcent l'assurance qualité, donc l'accountability.
- **Rapport** : rapport sur les feux de forêt dans l'UE en 2024, vérifié par 3 pairs qui « volent » les points en cas d'erreur factuelle. Effets attendus : relecture multiple comme norme, rapports plus courts et prudents, critique des sources.

CONCLUSION

Redéfinir le professionnel : garder le contrôle intellectuel de son travail. On supposait que la capacité à assumer responsabilité et accountability se développait d'elle-même, et l'on s'est concentré sur le savoir. Nouvelle `universitas` : les étudiants font comme les enseignants, ils relisent le travail. Question finale : `responsibility and accountability, new pillars for identity?`

Repris du cours 01 : responsibility gap, axiology of action. `REPRIS`

DRILL · 6 QUESTIONS

Questions d'entraînement

> Rédigées à partir des slides. Ce ne sont pas des annales : aucun sujet de ce cours n'est publié. Chaque réponse mobilise au moins deux cours.

QUESTIONS

1. What is the responsibility gap? Why can't accountability be delegated to AI, and what new balance between professionals and AI does it suggest?
2. Explain the Collingridge dilemma with the QWERTY example. Why is AI especially exposed to technological lock-in?
3. Present three of the five standpoints for the moral inclusion of AI. Which one do you find most convincing, and why?
4. What does the history of how animals were treated (Malebranche, Cartesian circles) suggest about a possible moral status of AI?
5. Compare functionalism and identity theory. What would each say about a mind running on artificial neurons?
6. Why are entry-level jobs particularly exposed to AI, and what is the training-pipeline problem?

Sources : ressources/moodle/aie2026-01.pdf à aie2026-05.pdf, export Moodle « Materials » du 2026-10-15. Slides 01 à 03 signées Mihály Héder, BME Department of Philosophy and History of Science.