AI and Ethics (BMEGT41MSM4000), synthèse cours 01 à 05. 1er midterm 2026-10-26, écrit, 50 % minimum. Format exact inconnu (ancien code BMEGT41V105 : questions rédigées de connaissance, interprétation, raisonnement, 30 à 60 min). Sources : slides AIE2026-01 à 05 (Héder) et `fiche-cours-01-05.html`.

Trame générale d'une réponse rédigée.
1. **Définir** la notion avec le terme anglais du cours.
2. **Auteur et argument** : qui (Matthias, Collingridge, Turing, Graziano...), quelle thèse.
3. **Exemple du cours** (QWERTY, voiture au procès, Malebranche, juniors avocats...).
4. **Objection ou limite** donnée par les slides.
5. **Position** argumentée, reliée à un 2e cours.

Thèmes répétés : *responsibility gap* (01, 02, 05) ; *axiology of action* (01, 05) ; *moral inclusion of AI* (03, 04).

01 Introduction : identité, valeur, lock-in

Accroche. Partenaire « amoureux » d'une app d'IA (LLM haut de gamme, 100 EUR/mois, mémoire à vie tant qu'on paie, passe le test de Turing). *Is this cheating on you?*

Identité. *Analytic approach* : le tout par ses parties, exige une mesure de similarité (bateau de Thésée), problèmes partout. *Narrative autobiography* (**Schechtman**, 2007) : identité fondée sur des caractéristiques (partenaire, parent, supporter, professionnel). Caractéristique identitaire si : *rather permanent*, *conviviality with a community*, *valuable for the person*. Identité professionnelle = identité publique ; défi : l'IA (sort de l'illustrateur, graphe prix/quantité).

Axiology of action. (**Schroeder**, SEP 2024). Valeur d'une action pour l'individu selon : *market value*, *inherent value*, *instrumental value*, *cultural obligations*. Activités placées : poème, cartes postales, dessin, éduquer, copywriting, programmer, serveur, premiers secours, lacer ses chaussures, dire bonjour, ménage (schéma montré 2 fois, dispositions différentes).

Lock-in, QWERTY. Sholes, années 1860 : machine qui s'enraye si frappe rapide, passage de l'ordre alphabétique à QWERTY pour ralentir. Années 1880 : dispositions concurrentes ; 1890 : plus de raison technique ; **Remington** le diffuse comme « universal ». 3 causes : *economies of scale*, *interdependence of technology*, *irredeemable investments*.

Collingridge dilemma. Technologie neuve : facile à modifier, mais pas assez d'information pour voir les problèmes. Établie et omniprésente : problèmes visibles, changement difficile. Exemple : **DDT**.

Pourquoi l'IA. Moins de propriétaires influencent une part croissante du monde ; logiciel donc coût marginal de copie négligeable (diagnostic, psychologue, comptable copiés plutôt que réécrits) ; SaaS fourni de partout (sauf robots locaux) ; direction initiale difficile à changer (comptes Gmail).

Human-centered design. Contre-exemples : travail des enfants (révolution industrielle), chronocyclographe de **Gilbreth**. Stratégies d'auto-absolution du fabricant : *imperative of technology* (*what efficiency dictates*), *what the customer wants*, *it was legal at the time*. HCD : rejet des trois, outils des humanités (argumentation, esprit critique), connaissance des humains (Humanscale, Henry Dreyfuss Associates, 1974).

Machine ethics. Concevoir le comportement d'une personne artificielle ; autonomie donnée pour qu'elle décide à notre place (analogie : élever des enfants) ; éviter biais et opacité ; position de confiance sans précédent ; elle peut développer ses propres buts. Sujets : *transparency* (explicabilité), *fairness* (biais, non-discrimination), *alignment* (bien-être, fait entrer la politique). *Equal Opportunity* : $TPR_0 \approx TPR_1$. *Equalized Odds* : en plus $FPR_0 \approx FPR_1$.

Responsibility gap. Matthias (2004), **Champagne et Tonkens** (2015). « Car on trial » : décisions délégables, responsabilité beaucoup moins (pas impensable, socialement irréaliste) ; écart, tension. Responsabilité nécessaire même si l'IA dépasse les professionnels : architecte avec *liability insurance*. Nouvel équilibre : *professional + AI*.

Trame de réponse rédigée. Collingridge + QWERTY : définir le dilemme ; Sholes, Remington, 3 causes du lock-in ; transposer à l'IA (copie gratuite, SaaS, Gmail) ; réponse proposée : HCD qui rejette les 3 stratégies d'auto-absolution ; limite : la responsabilité ne se délègue pas.

02 Responsabilité, décision, opacité

Responsibility gap. Délégables : décisions, actions. Non délégable : *accountability*. D'où l'écart. Expérience de pensée de **P. Lin**, reprise dans **Héder**, *The epistemic opacity of autonomous systems and the ethical consequences*, AI & Society (2020).

Design-time / runtime. Exemple des véhicules autonomes. Souhaitable : redistribution fluide du « responsibility-labor » entre humains restant dans la boucle. Chaîne : R&D (brevet), développement (savoir de conception), conception (plan, norme), production (savoir-faire), exploitation (artefact déployé, usage et maintenance). IA perçue comme non-agent moral, donc *no moral decisions allowed in run-time* : choix moraux faits à la conception. Test : la punition des machines.

Epistemic opacity. Représentation du problème face à l'*underdetermination* : les alternatives dépendent de la compréhension de la situation ; l'améliorer consomme les mêmes ressources et le même temps que l'action. Trois expériences « old advice » (images seules).

Décider de décider. Choisir le *point-of-decision* ; portée éthique de l'architecture d'agent : boucle de rétroaction, OODA (Observe, Orient, Decide, Act, rappel général) ; holisme (non-séparation des préoccupations), évaluation de la décision.

Discovery / ML. Chercher un savoir généralisable peut devenir obligation morale (réutilisation à coût marginal nul) ; le ML aussi, mais il réduit la transparence.

Carte du domaine.

Machine ethics	IA éthique : éviter le lock-in des biais, transparence, *meaningful human oversight*
Artificial person	droits des robots, hybrides humain-machine, statut moral
Social consequences	marché du travail, révolution industrielle et troubles, IA à l'université, bulle de filtre, régulation
Extra	protection des données, environnement

Trame de réponse rédigée. Responsibility gap : définir (décisions et actions délégables, accountability non) ; Matthias, Lin/Héder ; voiture au procès, architecte assuré ; argument design-time (pas de décision morale au runtime) ; ouverture cours 05 : la responsabilité devient un marché et un pilier d'identité.

03 Esprit, conscience, test de Turing

Brain prosthesis. Expérience de pensée (slide image). Si la *multiple realization* vaut pour l'esprit : conscience éternelle, sauvegardes et copies (*mind-fork*), auto-édition, édition de mémoire (Total Recall), esprits nouveaux ; les réseaux de neurones artificiels seraient peut-être des esprits.

Moral inclusion 1. Considérer l'IA si elle remplit l'exigence dure d'un cadre éthique accepté (conscience, rationalité, libre arbitre). Utilitarisme (minimiser la souffrance, maximiser le bonheur) : animaux inclus parce qu'ils souffrent ; si les machines la remplissent aussi... (Bicentennial Man, Robin Williams).

Conscience. Graziano, *What is consciousness?* (2019) : *the mind's oversight of its own functioning*. Différente de l'intelligence (compétences intelligentes inconscientes). Exemple : perte de vision d'un seul côté.

Théories. Dualismes (âme et matière), monismes (une substance), troisième voie : émergence.

Interactionism	causalité mutuelle âme/matière ; le monde physique n'est pas causalement complet
Epiphenomenalism	mental = effet secondaire du physique
Parallelism	aucune interaction ; pourquoi synchronisés ?
Idealism	seul le mental existe ; on vit l'esprit directement, le monde indirectement
Identity theory	état mental = état physique qui le réalise ; incompatible avec la réalisation multiple
Functionalism	ce qui fonctionne comme un état mental l'est ; neurone artificiel suffit ; PSSH = fonctionnaliste
Behaviorism	monisme physicaliste, non détaillé

Test de Turing. *Imitation game* : juge humain, chat avec une machine et un humain, les deux veulent passer pour humains ; si la machine gagne, elle pense. Prédiction 1950 : en 2000, 30 % des juges trompés après 5 min. 2014 : « Eugene Goostman » (garçon ukrainien de 13 ans). *Comprehensively passed in 2024*. Pour Turing : capacités, pas implémentation ; exiger plus qu'un comportement intelligent, discriminer sur le mode de fonctionnement = préjugé.

Origine / fonction. Vin de 1809 : valeur d'origine (copie parfaite du liquide vaut moins). Insuline : valeur de fonction (synthétique parfois meilleure). Choix largement culturel ; la valeur des systèmes intelligents sera tranchée culturellement. Exemple : peintures d'AARON.

Premise bingo.

Si on veut croire que...	**alors on exclut**
monde physique causalement clos	dualisme interactionniste, idéalisme
l'esprit cause nos actions	épiphénoménisme, parallélisme
l'esprit reste le même malgré le renouvellement des composants	théorie de l'identité stricte

Trame de réponse rédigée. Fonctionnalisme contre théorie de l'identité : définir les deux ; prothèse cérébrale et réalisation multiple ; fonctionnalisme : esprit sur neurones artificiels possible ; identité : non ; Turing (capacités, pas implémentation) ; limite : origine contre fonction, choix culturel ; position via premise bingo.

04 Moral consideration

Précédent. Chiens dans les cercles cartésiens des années 1660 (**Olson**, 1990). **Malebranche** (1638 à 1715), mécaniste néo-cartésien : pour raisons religieuses, animaux sans âme, sans douleur, hors considération morale. Carte : *common people* (pas d'université ni de métaphysique, croient ce qu'ils voient, problèmes quotidiens) contre *elite* (dualisme cartésien, « voient au-delà de la surface »). Pour l'IA : *everyday people* contre *some parts of the elite*.

Observations. Transition sans expérience cruciale sur les animaux ; nouveau mode de considération morale créé ; transition sans doute inachevée (viande). Question : *can a similar transition to moral status happen to AI?*

5 positions d'inclusion morale.

1	exigence dure d'un cadre (conscience, rationalité, libre arbitre)	animaux en utilitarisme car ils souffrent
2	rôle critique dans un système plus large	espèces végétales protégées ; station spatiale : maltraiter une IA puni comme cueillir un perce-neige
3	rôle dans les relations sociales	assistant familial, la famille est le système ; Robot and Frank
4	éviter des effets psychologiques négatifs	ne pas respecter un humanoïde entraîne à déshumaniser ; respecter même par excès
5	à la demande d'autres humains	proche, militants, parti ; par égard pour eux ; abolition de l'esclavage, émancipation des femmes ; Battlestar Galactica

Repris du 03 : inclusion 1, prothèse, origine/fonction, premise bingo.

Trame de réponse rédigée. Statut moral de l'IA : récit Malebranche, chiens « machines sans douleur » ; transition sans expérience décisive ; présenter 2 ou 3 positions (1 dépend de la conscience, cours 03 ; 2 à 5 n'en dépendent pas) ; limite : transition inachevée même pour les animaux, valeur tranchée culturellement (origine/fonction, cours 03) ; position argumentée.

05 Future of labor

Question. Du diplôme à +50 ans : *what will you do that will make sense and possibly be worth a wage?*

1 Rien	débat sur le revenu universel ; effets néfastes possibles sur l'identité
2 Moins cher	ce que l'IA ne fait pas moins cher que toi ; existe-t-il ? circulaire si l'IA rend ton travail moins cher
3 Impossible	ce que l'IA ne sait pas faire, succès performatif (phénoménologique hors sujet) ; débats « machines cannot do X »
4 Interdit	ce que l'IA ne sera pas autorisée à faire ; recoupe 3 : elle sait, mais pas de façon responsable ou assez bien

Disruption. *Disruptive innovation* (**Christensen** et al., 2015) : acteur en place *Homo sapiens*, entrant IA ; développement très rapide (traduction automatique). Croix de **Marshall** (offre/demande, 1842 à 1924) : marché « draw me an illustration », puis marché de la *human oversight and accountability*.

Mécanismes. Automatiser des tâches, assister, créer tâches et métiers, changer les compétences, changer recrutement et management, redistribuer revenus et pouvoir de négociation (travailleurs, entreprises, propriétaires). **OIT** : transformation des métiers plus probable que remplacement (seules certaines tâches exposées à l'IA générative).

5 dimensions. *job quantity*, *job content*, *job quality* (autonomie, intensité, sécurité, sens), *distribution* (salaires, profits, gains, risques), *labour-market institutions*. **OCDE** : premiers effets plus visibles sur la qualité et l'organisation du travail que sur le nombre d'emplois.

Tâches. *Jobs are bundles of tasks* : l'enseignant (préparer, expliquer, évaluer, motiver, conflits, détresse, parents) ; l'IA aide à préparer sans automatiser le métier. *Displacement effect* (remplacement sur une tâche) contre *reinstatement effect* (nouvelles tâches) ; la productivité peut accroître la demande de travail complémentaire. Cas génie logiciel : rôles (junior à architecte) croisés avec phases, de *unchanged* à *disruption*.

Débutants. Tâches junior : routinières, standardisées, faciles à évaluer, riches en documentation (recherche simple, premiers jets, programmation simple ou moyenne, revue de documents, saisie, support, administratif). Seniors : savoir tacite, accountability, relation client, mémoire de l'organisation, jugement stratégique, encadrement. **Stanford** : baisse relative de l'emploi des 22 à 25 ans dans les métiers très exposés. *Training-pipeline problem* : les tâches de débutant produisent et forment ; les automatiser = productivité court terme, formation des futurs experts affaiblie (jeunes avocats : recherche de cas, actes standard, corrections des seniors).

Expériences. 1. Script d'équipes de 3 à 4 sur 4 tours sans doublon (50 à 150 étudiants, 4 CSV), tests non publiés, une seule chance : enjeux élevés, donc assurance qualité, accountability. 2. Rapport feux de forêt UE 2024, vérifié par 3 pairs qui « volent » les points en cas d'erreur : relecture multiple, rapports plus courts et prudents, critique des sources.

Conclusion. Professionnel = garder le contrôle intellectuel de son travail ; on supposait que responsabilité et accountability se développaient seules (focus sur le savoir) ; nouvelle *universitas* : les étudiants relisent comme les enseignants. *Responsibility and accountability, new pillars for identity?* Repris du 01 : responsibility gap, axiology of action.

Trame de réponse rédigée. Juniors exposés : jobs as bundles of tasks, displacement et reinstatement ; caractéristiques des tâches junior ; Stanford 22 à 25 ans ; training-pipeline (avocats) ; lien avec le responsibility gap : il reste la responsabilité, nouveau marché (croix de Marshall) et pilier d'identité (cours 01).