FICHE DE RÉVISION · ZH MOODLE · 2026-12-02, 12H00

Lecture Note Booklet, Pejó

Résumé du livret de 42 pages, seule source de l'examen d'après l'enseignant (« the exam fully relies on its content, nothing more »). Termes et définitions en anglais, comme à l'examen. Type de questions : non annoncé.

Livret 42 p. Examen Moodle, 2026-12-02 Rattrapage 2026-12-09, IL108

Note 11 pts = 2, 26 pts = 5

FIL ROUGE

Privacy vs utility

Chaque défense coûte de la précision : bruit, généralisation, suppression, dimensions.

FIL ROUGE

L'anonymisation ne suffit pas

Sweeney, Netflix, De Montjoye, Census 2010 : tout se ré-identifie.

FIL ROUGE

Process vs output

K-anonymity juge la donnée publiée ; DP juge le mécanisme.

DATA · CHIFFRES DU LIVRET

Les chiffres à retenir

> Un QCM aime les chiffres. Tous ceux du livret, dans l'ordre du texte.

SUJET	CHIFFRE	CONTEXTE
Pubs ciblées	+40 % de clics, +50 % d'achats	Pubs adaptées aux traits de personnalité (Matz)
Likes Facebook	10 likes, 300 likes	Le modèle fait mieux qu'un collègue après 10 likes, qu'un conjoint après 300
Attention	25 à 60 bit/s contre 11 millions de bits	Débit de l'attention consciente contre information entrante
Sweeney 1997	Gouverneur du Massachusetts	Liste électorale : genre, code postal, date de naissance
Sweeney 2000	87 %	Population américaine unique par code postal, genre et date de naissance
Anonymity set	33 bits	8 milliards ≈ 2^{33} : 33 bits indépendants identifient une personne. Info gagnée : −log Pr(X = x)
Netflix 2007	1 000 000 $, 10 %, 99 %	Prix pour +10 % ; Shmatikov relie 99 % du jeu à IMDb. 2e concours annulé par la FTC
Réseaux 2009	31 %	Flickr (3,3 M users, 53 M liens) et Twitter (224 000 users, 8,5 M liens) ; topologie seule

SUJET	CHIFFRE	CONTEXTE
Appels 2011	3 mois, 25 M users, 30 Md d'appels	Les top K lieux sont uniques ; dégrader la donnée protège peu
Mobilité 2013	2 points : 50 %, 4 points : >95 %	15 mois, 1,5 M personnes (De Montjoye)
Carte bancaire 2015	4 magasins sur 10 000, 90 %	1,1 M clients, horodatage au jour près
Code 2015	70 % puis 98 %, 93 % sur 1 600	Google Code Jam : 250 programmeurs, 9 tâches, ~70 lignes, Random Forest, 1 puis 9 échantillons
Conduite (CrySyS)	85 %, 2 minutes	Trois douzaines de conducteurs, bus CAN, en ville, même sur un autre trajet
TLS 2023	>90 %	Webpage fingerprinting sur trafic chiffré
Census 2010	46 %, >50 millions	Microdonnées reconstruites, puis ré-identification nominative. En 2020 le Census passe à la DP
Dimensions	>1000 et <10	Au-dessus de 1000, la privacy se dégrade ; en dessous de 10, l'utilité
L-diversity	3-diversity > 100-anonymity	3-diversity coûte plus de données que 100-anonymity
Loi allemande	il y a 50 ans	Première loi de protection des données (Bundesdatenschutzgesetz)
Snowden	2013	Programmes de surveillance de la NSA
Telegram	2017	Le FSB exige le déchiffrement, refus, blocage en Russie
Monero / ZCash	Anonymity set 12 / tous	Signatures de groupe contre ZKP
E-voting	Estonie 2005, Suisse 2016	Élections nationales, puis cantonales

Introduction

> La privacy n'est pas qu'une question de confidentialité : les systèmes doivent aussi protéger la liberté d'expression, l'autonomie et l'autodétermination. Trois questions structurent le domaine : quoi protéger, contre qui, comment.

LES 3 QUESTIONS

- **What** : contenu des communications, habitudes d'usage, ou simple existence ou activité de l'utilisateur.
- **From whom** : l'`adversarial model`. Autres utilisateurs, ou le fournisseur de service lui-même.
- **How** : typiquement, couper le lien entre la personne et ses données.

Les défenses portent le nom collectif de `Privacy Enhancing Technologies (PET)`. Remarque du livret : les PET peuvent servir à des activités illégales ; les mécanismes de levée sélective affaiblissent la sécurité, et aucune solution n'est infaillible.

CH. 2.1 · P. 4 à 9

Tracking

> Avant d'exploiter les données, il faut les collecter. Tracking, profilage, dark patterns et biais cognitifs alimentent les data brokers, qui font fuiter les données même sans fuite de données.

DÉFINITIONS

- `Tracking` : observation et enregistrement de l'activité en ligne des utilisateurs. Motivation principale : la publicité ciblée.
- `Profiling` : enregistrement et analyse des caractéristiques psychologiques et comportementales d'un utilisateur, pour évaluer ou prédire ses capacités ou le catégoriser. Danger : manipuler la démocratie (Cambridge Analytica).
- `Dark patterns` : interfaces conçues pour pousser l'utilisateur à agir contre son intérêt. Exemples : `privacy zuckering` (consentement forcé, trick wording, preselection) et `obstruction` (réglages cachés dans des menus imbriqués).
- `Cognitive bias` : écart systématique à la norme ou à la rationalité dans le jugement. Modèle de Fogg : il faut assez de motivation et de capacité pour déclencher un comportement.
- `Anchoring` : la première information pèse sur la suite, d'où le `default effect`. `Hyperbolic discounting` : on préfère le confort immédiat aux problèmes futurs.

WEB TRACKING

MÉTHODE	PRINCIPE
Cookies	Petits fichiers texte stockés dans le navigateur. Les cookies tiers servent aux régies pour suivre l'utilisateur entre sites
Fingerprinting	Combine les caractéristiques de l'appareil et du navigateur (résolution, OS, extensions, version, polices, matériel) en une empreinte unique
Social button	« Like », « Tweet » : la plateforme est notifiée de la visite même sans clic. Défenses : bloquer les cookies, uBlock Origin, Privacy Badger, désactiver les intégrations, navigation privée
Web beacon	Image ou code minuscule et invisible dans une page ou un mail. Suit l'activité dans une seule page ou un seul mail, alors que le cookie suit entre sites

DATA BROKERS

`Data broker` : personne ou société qui collecte des données personnelles et les vend à des tiers. Usages : marketing, détection de fraude et risque de crédit (banques), calcul des primes (assureurs). `Information leakage` : les données sortent des serveurs de sociétés de confiance sans aucune brèche, par le commerce entre fournisseurs. Exemple : une recherche « HIV » sur un site de santé n'a pas la protection du secret médical.

Re-identification

> Retirer le nom ne protège pas l'identité. Données structurées, non structurées, agrégées et modèles de ML se ré-identifient tous.

DÉFINITIONS

- `PII` : attribut unique et lié sans ambiguïté à une personne réelle (nom, adresse, téléphone).
- `Matching attack` : l'attaquant a une connaissance préalable sur sa cible et cherche l'enregistrement anonyme qui lui correspond.
- `Identity disclosure` : relier un enregistrement anonyme à la personne. `Attribute disclosure` : révéler un attribut inconnu de la cible. La seconde est plus forte : elle n'a pas besoin de la première (exemple : tous les vingtenaires du jeu ont une otite).
- `Quasi-identifier` : insuffisant seul, identifiant une fois combiné à d'autres.
- `Anonymity set` : ensemble d'enregistrements parmi lesquels le sujet ne peut pas être distingué.

MATCHING

Algorithme courant : `K-NN`. Distances : euclidienne ou Earth Mover's pour des données homogènes (localisation), Hamming ou Mahalanobis pour des données hétérogènes (genre, métier). Poids des attributs par PCA ou entropie. Limite : la `curse of dimensionality`.

Théorème : si $A \subseteq B$ (le fond de connaissance contient tous les anonymisés), méthode hongroise en $O(|B|\cdot|E|^2)$. Sinon, avec $r = |B \cap A| < |A|$ bien estimé, méthode hongroise modifiée en $O(|A|\cdot|B|\cdot r)$.

Types de données : non structurées (texte, images) ; structurées agrégées (histogrammes) ou microdonnées : relationnelles, séquentielles (séries temporelles), set-valued ou transactionnelles, hybrides.

NON STRUCTURÉ

- **Code** : `stylometry`. Caractéristiques de mise en page (espaces contre tabulations, lignes vides), lexicales (paramètres de fonctions, profondeur d'imbrication) et syntaxiques (`AST`, invariant à l'apparence). Survit même à la compilation.
- **Conduite** : bus `CAN`, ré-identification par les motifs de communication, sans connaître l'emplacement des signaux.
- **Trafic chiffré** : `webpage fingerprinting` sur la séquence et la taille des requêtes, distance de Damerau-Levenshtein. TLS protège les données (carte bancaire), pas les habitudes de navigation.

AGRÉGÉ

`Reconstruction attack` : chaque statistique publiée devient une équation sur des inconnues ; on résout le système (élimination de Gauss). Au moins une solution existe ; si les statistiques sont restrictives, elle est probablement unique. Le cas général est NP-difficile : on utilise des heuristiques comme les SAT solvers.

ML

Un modèle est une forme de donnée agrégée ; l'`overfitting` le fait mémoriser. Modèles d'attaquant : `black box` contre `white box`, `active` contre `passive`.

ATTAQUE	BUT	TYPE
`Membership inference`	Savoir si un enregistrement était dans l'entraînement. Surtout utilisée pour l'audit	Privacy
`Model inversion`	Retrouver la moyenne des échantillons d'une classe (visages sur fond uniforme)	Privacy
`Data reconstruction`	Retrouver un échantillon exact à partir du modèle et du gradient	Privacy
`Property inference`	Propriété globale du jeu d'entraînement, sans rapport avec la tâche (nombre de femmes employées)	Privacy
`Model extraction`	Copie fonctionnelle du modèle : propriété intellectuelle	Confidentiality
`Evasion`	Exemples adverses, à l'inférence	Security
`Poisoning`	Échantillons malveillants, à l'entraînement	Security
`Backdoor`	Déclencheur caché, actif en production	Security

CH. 3.1 · P. 19 à 22

GDPR

> Le GDPR définit ce qui est personnel, ce qui est sensible et quand on peut traiter. Le problème n'est pas la loi, c'est son application.

CHAMP

S'applique selon la localisation, pas la nationalité : à toute organisation qui traite des données de personnes résidant dans l'UE, ou dont le responsable ou le sous-traitant est établi dans l'UE. Les lois nationales ne peuvent pas être plus faibles.

`Data protection` : droit à la protection de toute information sur une personne physique vivante identifiée ou identifiable. Droit fondamental (UE et ONU). Restreignable selon la `necessity` et la `proportionality`.

DÉFINITIONS

- `Personal data` : information relative à une personne physique identifiée ou identifiable.
- `Identifiability` : il existe une attaque `plausible` (motivation, temps, argent) avec une chance `reasonable` de succès. Pas de seuil fixé, volontairement, pour tenir compte du contexte.
- `Anonymous data` : définie implicitement, tout ce qui n'est pas personnel. Le WP29 (prédécesseur de l'EDPB) exigeait l'impossibilité de `singling out`, `linkability` et `inference` : ensemble, trop fort.
- `Sensitive data` : origine raciale ou ethnique, opinions politiques, convictions religieuses ou philosophiques, appartenance syndicale, biométrie, génétique, santé, orientation sexuelle. Traitement interdit sauf 5 cas : recherche ou santé publique, consentement explicite, données déjà rendues publiques par la personne, action en justice, intérêts vitaux.

BASE LÉGALE

Données non sensibles : traitement licite si `legitimate interest` du responsable (la base la plus abusée) ou `consent` (obtenu en exploitant l'inattention). Textes contre les dark patterns : UCPD, DSA, GDPR. Cause du problème : autorités débordées, sous-financées, en sous-capacité.

Anonymization

> Des techniques de base combinées selon une définition formelle. K-anonymity protège l'identité, L-diversity l'attribut sensible ; aucune ne compose.

PRIMITIVES

TECHNIQUE	PRINCIPE
`Pseudonymization`	PII remplacés par des pseudonymes ; table de correspondance conservable, donc réversible
`Masking`	PII supprimés ou cachés ; idéalement irréversible
`Swapping`	Échange aléatoire de valeurs entre enregistrements ; distribution conservée
`Obfuscation`	Ajout de bruit ; protection **uniforme** entre enregistrements
`Deletion`	Suppression ; protection **non uniforme**. Sous-types : suppression (enregistrements entiers), sampling (chaque enregistrement supprimé avec une probabilité)
`Generalization`	Moins de granularité. Sous-types : clustering (centroïde), rounding (tranche d'âge), thresholding (valeurs extrêmes écrêtées)

MODÈLES

- `Syntactic model` : conditions sur la donnée publiée, connaissance de l'attaquant supposée connue. Protection parfaite, mais seulement contre certains attaquants.
- `Semantic model` : limite la fuite pour tout attaquant, sans l'empêcher. Universel, pas parfait.
- `Absolute privacy` : rien apprendre de plus qu'en l'absence de la base. Impossible si on veut garder de l'utilité.

K / L

`K-anonymity` (Sweeney) : chaque combinaison de quasi-identifiants présente apparaît au moins K fois. Contre l'identity disclosure. Mise en œuvre : généralisation globale (analyse plus simple) ou locale (plus précise), et suppression des outliers. Pas de valeur de K imposée par la loi : on paie des consultants.

`L-diversity` : chaque attribut sensible apparaît au moins L fois dans chaque anonymity set. Contre l'attribute disclosure. Théorème : **L-diverse implique L-anonyme**. Peu utilisé : trop coûteux en données.

QUERY AUDITING

Protéger un attribut confidentiel tout en répondant à des agrégats (SUM, COUNT, MEDIAN, MAX). Deux approches : `detection` et `prevention`, toutes deux par refus de répondre. Alternative : la `perturbation`.

- Sans bruit : $O(N^2 \cdot \log N)$ requêtes aléatoires reconstruisent une base de N enregistrements avec probabilité $1 - 1/N^2$.
- Avec bruit d'amplitude maximale E : les 2^N requêtes reconstruisent tout sauf $4 \cdot E$ enregistrements.

Differential Privacy

> La DP est une propriété du processus, pas de la sortie. En voyant le résultat, on ne peut pas savoir si une personne donnée était dans la base. Plus ε est petit, plus la protection est forte.

DÉFINITION

`ε-DP` : M est ε-DP si pour toutes bases voisines D et D' (un enregistrement de différence) et toute sortie O : $Pr[M(D) = O] \leq e^{\varepsilon} \cdot Pr[M(D') = O]$, avec $\varepsilon > 0$ le `privacy budget`.

Nom : la « dérivée » du mécanisme est bornée. Relâchement de l'indistinguabilité cryptographique. Protection parfaite possible, mais avec un bruit infini. Définition symétrique ; en continu, « $\in S$ » au lieu de « $= O$ ».

`(ε, δ)-DP` : ajoute + δ, la garantie peut être violée avec une petite probabilité δ, idéalement bien plus petite que l'inverse de la taille de la base. Plus de précision.

BRUIT

- **Laplace** : peu de requêtes, garantie ε-DP pure, moins d'utilité.
- **Gauss** : beaucoup de requêtes, moins de bruit, plus précis, garantie plus faible.

Le livret écrit que le bruit gaussien n'atteint que « ε-DP », ce qui contredit « garantie plus faible ». Rappel général : le mécanisme gaussien donne une garantie (ε, δ)-DP. Si la question tombe, retenir « Gauss : garantie plus faible, (ε, δ) ».

`Sensitivity` : $\Delta M = \max ||M(D) - M(D')||$ sur les bases voisines. Plus elle est grande, plus il faut de bruit. À ne pas confondre avec les `sensitive data` du GDPR.

Exemple du livret : 10 salariés, somme 10 000 000 HUF ; sans Peter, 9 000 000. Réponse bruitée 10 100 000 : soit 9 personnes et bruit de 1 100 000, soit 10 personnes et bruit de 100 000. L'attaquant ne peut pas trancher.

PROPRIÉTÉS

- `Bayes` : la DP borne l'écart entre croyance a priori et a posteriori sur $D = D_{in}$ ou D_{out}.
- `Composition` : deux mécanismes ε-DP donnent **2ε-DP en séquentiel**, **ε-DP en parallèle**.
- `Post-processing` : toute transformation f(M(·)) reste DP.
- K-anonymity et L-diversity ne vérifient **ni l'une ni l'autre**.

MODÈLES

`Central DP` : serveur de confiance, bruit ajouté à la sortie. `Local DP` : serveur non fiable, chaque utilisateur bruite sa donnée ; plus protecteur, moins utile. Exemple : `randomized response` (pile : vérité ; face : seconde pièce secrète), qui donne la `plausible deniability`.

DÉFENSES ML

Cadre : `Trustworthy AI` (précision, sécurité, privacy, équité, explicabilité), en tension mutuelle ; l'EU AI Act les exige. Un modèle très explicable fuit davantage. Défenses empiriques : retirer les données sensibles ou ajouter des fausses avant l'entraînement ; pendant, `quantization`, `sparsification`, `truncation` des gradients ; après, arrondir les probabilités ou ne renvoyer que la prédiction. `Defense in depth` : protéger tout le système (filtrage des entrées, adversarial training, masquage des sorties, surveillance des API) ; randomiser les défenses augmente le coût de l'attaquant.

`Machine unlearning` : retirer l'influence d'un échantillon d'un modèle entraîné, pour le « right to be forgotten ». Ré-entraîner est souvent trop coûteux.

Cryptography

> La cryptographie moderne remplace le tiers de confiance par des mathématiques : on calcule et on prouve sans jamais exposer la donnée.

PRIMITIVES

PRIMITIVE	DÉFINITION ET EXEMPLE
HE	Calculer sur des données chiffrées et obtenir un résultat chiffré. Exemple : statistiques sur données de santé chiffrées
PHE	Une seule opération, nombre illimité de fois
SHE	Deux opérations, dont une un nombre limité de fois
FHE	Deux opérations, nombre illimité de fois. Possible mais très coûteux
SMPC	Plusieurs parties calculent une fonction commune sans rien apprendre de plus que le résultat. Exemple : revenu moyen entre amis. HE quand la donnée est en un lieu, SMPC quand elle est distribuée
`(k, n)` SSS	Secret découpé en n parts, k suffisent. Sûr si moins de k parts n'apportent aucune information
ZKP	Le prover convainc le verifier qu'une affirmation est vraie sans rien révéler d'autre. Exemple : prouver une épargne mensuelle à la banque

Les 3 propriétés d'un ZKP : `completeness` (vrai, le protocole répond toujours vrai), `soundness` (faux, il ne peut pas répondre vrai), `zero-knowledge` (le verifier n'apprend que la validité).

CH. 3.5 · P. 34 à 40

Privacy Enhancing Technologies

> Messagerie sécurisée, communication anonyme, cryptomonnaies et vote électronique : les primitives assemblées en outils réels.

PET SIMPLES

`TEE` (environnement isolé dans le processeur, protégé même de l'OS), `anti-tracking`, `VPN` (cache IP et localisation), `password managers`, `2FA`, `encrypted cloud storage` (seul l'utilisateur a les clés).

SECURE MESSAGING

Attaquant actif (modifie) ou passif (écoute) ; les participants sont honnêtes, le fournisseur peut être malveillant. Au-delà de l'intégrité et de la causalité (ordre des messages) :

- `End-to-end encryption` : seuls les participants déchiffrent.
- `Perfect forward secrecy` : une clé compromise ne révèle pas les messages **passés**.
- `Future secrecy` : une clé compromise ne révèle pas les messages **futurs**.

Signal : open source (GPLv3), asynchrone, E2E, PFS et future secrecy. Base de WhatsApp et Messenger. **Pas d'anonymat** : le serveur stocke les clés publiques.

ANONYMAT

Le chiffrement ne cache pas les métadonnées (qui, quand, combien de temps, combien de messages). Coûts : latence, bande passante, fonctionnalités. Garanties : `sender and receiver anonymity`, `unlinkability` (impossible de dire si deux éléments sont liés), `undetectability` (impossible de dire si un message existe).

- `MIX` : proxy qui change l'encodage, reçoit par lots et change l'ordre. Garantit l'anonymat de l'émetteur face au destinataire et l'unlinkability émetteur-destinataire face à un écouteur global. Réseau de MIX : chiffrement en couches à clé publique, prouvé sûr mais très lent.
- `Tor` : basé sur les MIX, compromis anonymat contre vitesse. Chiffrement symétrique, **pas de mixing, seulement du forwarding**. Adversaire **local** seulement : un attaquant global retrouve les métadonnées. 3 onion routers (entry, middle, exit) qui changent chaque minute. Politiques de sortie : relay, private exit.

CRYPTO-MONNAIES

Blockchain (DLT) : vérifiabilité publique, intégrité, transparence ; la privacy passe après. Bitcoin : transactions publiques, adresses reliables par `chainalysis`, pseudonymat faible. Anonymat complet : MIX (mais il faut lui faire confiance), signatures de groupe (**Monero**, anonymity set 12), ZKP (**ZCash**, tous les utilisateurs ; **Tornado Cash** sur Ethereum). Tornado Cash mis sur la liste OFAC, puis une cour d'appel juge qu'un protocole ne peut pas être rendu illégal.

E-VOTING

GARANTIE	SENS
`Ballot secrecy`	Seul l'électeur connaît son vote
`Receipt-freeness`	Impossible de prouver son vote (contre l'achat de votes)
`Coercion resistance`	Voter selon son intention tout en paraissant obéir
`Individual verifiability`	Chacun vérifie que son vote est bien enregistré
`Universal verifiability`	Tout le monde vérifie le décompte
`Eligibility verifiability`	Tout le monde vérifie que seuls des votes valides, un par personne, ont été émis

Outils : ZKP (prouver un vote valide sans le révéler), HE (compter les votes chiffrés), blockchain (transparence, intégrité). Papier : secret facile, vérification difficile.

TRAPS · 12 PAIRES

Confusions à éviter

PAIRE	DIFFÉRENCE
Identity / attribute	L'attribute disclosure est plus forte et ne nécessite pas l'identity disclosure
Pseudonym. / masking	Réversible par table / suppression irréversible
Obfuscation / deletion	Protection uniforme / non uniforme
Syntactic / semantic	Parfait contre certains attaquants / limité contre tous
K-anon. / L-div.	Protège l'identité / l'attribut sensible. L-diverse implique L-anonyme
Output / process	K-anonymity juge la donnée / la DP juge le mécanisme
Séquentiel / parallèle	2ε / ε
Central / local	Serveur de confiance / non fiable, plus protecteur, moins utile
Sensitivity / sensitive	Notion DP / catégorie GDPR
PFS / future secrecy	Messages passés / futurs
MIX / Tor	Mélange et réordonne, lent / ne mélange pas, rapide, adversaire local
Extraction / inversion	Vole le modèle (confidentialité) / retrouve la moyenne d'une classe (privacy)

DRILL · 16 VRAI OU FAUX

Format des quiz : deux réponses possibles

> Questions rédigées à partir du livret, pas des annales. Clique pour voir la réponse. En quiz réel, une erreur coûte −2 : abstiens-toi si tu hésites.

01 Attribute disclosure requires identity disclosure first.

False. Elle est plus forte justement parce qu'elle n'en a pas besoin (p. 9).

02 87% of the US population is unique by ZIP code, gender and date of birth.

True. Sweeney, 2000 (p. 12).

03 Pseudonymization keeps a mapping table, so the data can be restored.

True. Le masking, lui, est idéalement irréversible (p. 23).

04 Deletion protects all records uniformly.

False. C'est l'obfuscation qui est uniforme ; la deletion laisse certains enregistrements sans protection (p. 24).

05 If a dataset is L-diverse, it is also L-anonymous.

True. Théorème du livret (p. 26).

06 K-anonymity satisfies the post-processing property.

False. Ni K-anonymity ni L-diversity ne vérifient composition et post-processing (p. 31).

07 Differential privacy is a property of the output data.

False. C'est une propriété du processus (p. 27).

08 A smaller ε means stronger protection.

True (p. 28).

09 Two ε-DP mechanisms composed sequentially give ε-DP.

False. 2ε en séquentiel, ε en parallèle (p. 31).

10 Local DP gives stronger protection but lower utility than central DP.

True (p. 31).

11 Model extraction is primarily a privacy threat to training data.

False. C'est une menace de confidentialité sur le modèle lui-même (p. 18).

12 Somewhat HE supports two operations, one of them only a limited number of times.

True (p. 33).

13 Signal provides anonymity.

False. Le serveur stocke les clés publiques (p. 36).

14 Tor mixes messages to resist a global adversary.

False. Pas de mixing, seulement du forwarding, contre un adversaire local (p. 38).

15 Perfect forward secrecy protects past messages when a key is compromised.

True. La future secrecy protège les messages futurs (p. 36).

16 Receipt-freeness prevents vote-selling.

True. L'électeur ne peut pas prouver son vote (p. 40).

Source : ressources/Privacy-PPT-EN.pdf, « Lecture Note Booklet », Balázs Pejó, 42 pages. Numéros de page du livret. Format et type de questions de l'examen : À VÉRIFIER.