Exercices corrigés

Embedded Artificial Intelligence, cours 01 à 06, TP 1 à 4

BMEVIMIMA22, automne 2026. Rédigé le 2026-09-28, complété le 2026-10-17. Midterm le 2026-10-29, 18h à 20h.

À retenir

- **Énoncés** : 80 questions en 21 niveaux. Niveaux 1 à 9 (Q1 à Q42) : cours 1 et 2, TP 1 et 2. Niveaux 10 à 21 (Q43 à Q80) : classification, clustering, PCA, cas d'usage du cours 5, réseaux de neurones, soit tout le programme du midterm. QCM (une ou plusieurs bonnes réponses, le nombre n'est pas indiqué), VRAI/FAUX et questions ouvertes.
- **Corrigés** : dans une partie séparée, avec le calcul déroulé et la source.

Statut. Exercices d'entraînement écrits pour ce document, pas des sujets officiels ni des annales : l'enseignant a promis les sujets des années précédentes, pas encore reçus. Le format suit ce qu'il a annoncé (QCM et questions ouvertes) et le gabarit des séries d'entraînement 2026 (VRAI/FAUX à $+1$ et -1, calculs courts). Les données chiffrées viennent des slides quand la question le dit ; les autres (jeux de points, tableaux de seuils, poids du réseau) sont des données d'exercice. Tous les résultats ont été recalculés par script (`exams/latex/calc_embai.py` pour les niveaux 1 à 9, `exams/latex/calc_embai_s36.py` pour les niveaux 10 à 21) ; toutes les sorties de code ont été obtenues en exécutant le code.

À faire aussi. Les deux séries publiées par l'enseignant sont corrigées dans `fiche-midterm-practice.pdf` (un pas d'apprentissage sur un réseau à deux couches, courbes d'activation, k-means, matrice de confusion, dendrogramme, gain d'information), avec six variantes. Les niveaux 10 à 21 ci-dessous n'en reprennent pas les données.

Piège

Les slides du cours 6 (réseaux de neurones) manquent : les niveaux 19 à 21 s'appuient sur les supports du TP 4 (`NN2a`, `NN4a`, `NN8`), dont la convention d'erreur est $E = \frac{1}{2}e^2$. Les annales de l'enseignant prennent

> $E = \varepsilon^2$: le niveau 20 donne les deux.

Méthode. Sur papier, sans calculatrice pour les niveaux 1 à 5, 7, 10 et 16, avec calculatrice simple pour les autres. Le cours est dans « Embedded AI, cours et méthodes » ; les numéros de concept cités renvoient à ce document.

Table des matières

1 Énoncés **5**

1.1 Niveau 1. Systèmes embarqués et IA 5
1.2 Niveau 2. Ordres de grandeur 6
1.3 Niveau 3. Complexité 7
1.4 Niveau 4. Apprentissage automatique 7
1.5 Niveau 5. Défis, cloud et local, matériel 8
1.6 Niveau 6. Énergie et représentation des nombres 9
1.7 Niveau 7. Python et NumPy 10
1.8 Niveau 8. Régression linéaire 11
1.9 Niveau 9. Régression logistique 11
1.10 Niveau 10. VRAI/FAUX, cours 3 à 6 12
1.11 Niveau 11. kNN et coût des calculs 13
1.12 Niveau 12. Entropie 13
1.13 Niveau 13. Arbre de décision 14
1.14 Niveau 14. Matrice de confusion et ROC 15
1.15 Niveau 15. Distances et k-means 16
1.16 Niveau 16. Clustering hiérarchique 16
1.17 Niveau 17. PCA 17
1.18 Niveau 18. Cas d'usage : détection de chute 17
1.19 Niveau 19. Neurone et activations 18
1.20 Niveau 20. Un pas de rétropropagation (type quiz 06.3) . . . 18
1.21 Niveau 21. Vanishing gradient et généralisation 19

2 Corrigés **20**

2.1 Niveau 1 20
2.2 Niveau 2 21
2.3 Niveau 3 22

2.4 Niveau 4 23
2.5 Niveau 5 24
2.6 Niveau 6 24
2.7 Niveau 7 25
2.8 Niveau 8 26
2.9 Niveau 9 27
2.10 Niveau 10 28
2.11 Niveau 11 29
2.12 Niveau 12 29
2.13 Niveau 13 30
2.14 Niveau 14 32
2.15 Niveau 15 33
2.16 Niveau 16 34
2.17 Niveau 17 35
2.18 Niveau 18 35
2.19 Niveau 19 36
2.20 Niveau 20 36
2.21 Niveau 21 38

1. Énoncés

Niveau 1. Systèmes embarqués et IA

Q1. QCM. Pour la surveillance environnementale (motards dans une forêt protégée, `01_Intro` slide 9), quelles contraintes la slide classe-t-elle comme importantes ?

(a) le temps de réponse

(b) la consommation des appareils, sur batterie

(c) la puissance de calcul

(d) un appareil petit, léger et robuste

Q2. Citer cinq différences entre un système embarqué et un ordinateur généraliste.

Q3. QCM. Quelles applications la slide 17 de `01_Intro` encadre-t-elle comme typiquement embarquées ?

(a) conduite autonome

(b) recommandation de produits

(c) surveillance environnementale

(d) trading boursier

(e) prédiction du trafic

Q4. Définir la rationalité au sens du cours. Quelle case du tableau « penser, agir, comme un humain, rationnellement » retient-il, et pourquoi la voie humaine n'est-elle pas forcément la meilleure ?

Q5. Vrai ou faux ? (a) Le DL est un sous-ensemble du ML. (b) En ML, l'information est donnée sous forme de règles et de formules. (c) L'IA générative est un sous-ensemble du DL. (d) D'après le schéma de la slide 18, l'IA embarquée est un sous-ensemble du DL.

Q6. Comparer une méthode fondée sur un modèle et une méthode d'apprentissage sur l'exemple du circuit de `01_Intro` (slides 20 et 21). Quelles difficultés ont-elles en commun ?

Q7. QCM. Quels avantages d'EdgeAI la slide 29 de `01_Intro` cite-t-elle ?

(a) latence réduite

(b) puissance de calcul supérieure au cloud

(c) confidentialité des données

(d) fonctionnement sans connexion au serveur

(e) entraînement plus rapide des modèles

Q8. Définir la quantification et l'élagage. Lequel réduit le nombre de paramètres, lequel réduit la taille de chacun ?

Niveau 2. Ordres de grandeur

Q9. ChatGPT reçoit $2 \cdot 10^9$ requêtes par jour à 0,34 Wh chacune (`01_Intro` slide 26). Calculer l'énergie par jour. La Hongrie consomme $0{,}85 \cdot 10^9$ Wh en 10 minutes : à combien de minutes de consommation du pays cela correspond-il ?

Q10. Entraîner GPT-3 a consommé 1 287 000 kWh pour 168 597 $, GPT-4 62 318 800 kWh (slide 25). Convertir l'énergie de GPT-4 en Wh, calculer le rapport GPT-4 sur GPT-3 et le prix du kWh utilisé.

Q11. AlphaGo consommait environ 1 MW (`02_Challenges` p. 17). Combien de cerveaux humains (20 W) cela représente-t-il ? Combien de corps humains (100 W) ?

Q12. D'après le tableau p. 10 de `02_Challenges`, calculer le rapport des temps d'entraînement de ResNet152 et ResNet18, et le gain d'erreur. Même question de ResNet101 à ResNet152. Commenter.

Niveau 3. Complexité

Q13. Rappeler la définition de $T(N) = O(F(N))$. Montrer que $T(N) = 3N^2 + 5N + 2$ est $O(N^2)$ en donnant c et N_0.

Q14. Problème des pièces (`01_Intro` slide 32). Pour $N = 27$ puis $N = 100$, donner le nombre de pesées de la force brute, de la méthode par moitiés et de la méthode par tiers. Décrire la méthode par tiers pour $N = 9$.

Q15. Un camarade affirme : « $O(\log_3 N)$ est une meilleure classe de complexité que $O(\log_2 N)$ ». Qu'en penser ?

Q16. Pour $N = 1000$, comparer le nombre d'opérations du tri à bulles (pire cas) et du tri fusion. Lequel choisir sur un microcontrôleur à très peu de mémoire vive, et à quel prix ?

Q17. Appliquer une passe de tri à bulles à la liste de la slide 34, [3,9; −2; 1; 7; 12; 5; −2,37]. Combien d'échanges ? Combien de passes au total jusqu'à une passe sans échange ?

Niveau 4. Apprentissage automatique

Q18. Dire s'il s'agit d'apprentissage supervisé, non supervisé ou par renforcement. (a) Des photos étiquetées « chat » ou « chien ». (b) Regrouper des clients selon leurs achats, sans catégorie connue. (c) Un robot joue une partie et n'est récompensé qu'à la fin. (d) Prédire V_2 à partir d'un tableau de mesures (V_1, ω, V_2).

Q19. QCM. Parmi ces systèmes entraînables, lesquels la slide p. 8 de `02_Challenges` classe-t-elle comme typiquement non supervisés ?

(a) K-means

(b) arbre de décision

(c) clustering hiérarchique

(d) plus proche voisin

Q20. Pourquoi n'entraîne-t-on généralement pas un modèle sur l'appareil embarqué ? Que fait-on parfois à la place ?

Niveau 5. Défis, cloud et local, matériel

Q21. QCM. Parmi ces affirmations sur le mode cloud (`02_Challenges` p. 24), lesquelles sont justes ?

(a) il aide pour les limites de mémoire

(b) il améliore le temps de réaction

(c) il n'aide pas pour l'énergie locale limitée

(d) il dépend d'une communication à bande passante limitée et peu fiable

Q22. Le scandale des allocations familiales néerlandaises (`02_Challenges` p. 21 et 22) illustre plusieurs problèmes de confiance. Les nommer et relier chacun à un fait.

Q23. Classer dans sûreté, confiance ou gouvernance : (a) un attaquant modifie l'appareil physiquement ; (b) le modèle est une boîte noire ; (c) il n'existe pas de réglementation pour l'application ; (d) une décision est prise trop vite faute de temps de calcul ; (e) mettre à jour le système sans l'interrompre.

Q24. QCM. Associations justes (`02_Challenges` p. 29) ?

(a) CPU : orienté latence

(b) GPU : orienté latence

(c) FPGA : logique programmable

(d) ASIC : logique figée

Niveau 6. Énergie et représentation des nombres

Q25. Avec le tableau de `02_Challenges` p. 33, calculer : lecture DRAM contre addition entière 32 bits ; lecture DRAM contre lecture SRAM ; multiplication flottante 32 bits contre multiplication entière 8 bits (énergie et surface).

Q26. Un modèle effectue 10^6 multiplications-additions en FP32 et lit ses 10^6 poids en DRAM à chaque inférence. (a) Énergie de calcul, énergie mémoire, total et part de la DRAM. (b) Même total si les poids sont en SRAM. (c) Énergie de calcul en entiers 8 bits. (d) Énergie consommée en une heure à 10 inférences par seconde (cas DRAM).

Q27. La puissance d'une DRAM est $P = \frac{1}{2}\sum_i C_i V_i^2 f_i$. Par combien est multipliée P si l'on divise la tension par 2 ? la fréquence par 2 ? les deux ? si la tension passe de 1,2 V à 1,0 V ?

Q28. (a) Combien de bits de signe, d'exposant et de mantisse en FP16 ? (b) Valeur maximale d'un int8 à 1 bit de signe et 7 bits de magnitude ? (c) La slide p. 32 donne pour Int16 une étendue de 0 à $6 \cdot 10^4$: est-ce cohérent avec 15 bits de magnitude ?

Q29. Calculer la taille mémoire de VGG16 (134,2 M de paramètres) en FP32, FP16 et int8. Même question pour ResNetV1 50 (25,6 M) en FP32, en Mo puis en Mio, et comparer à la slide p. 13 (97,7).

Niveau 7. Python et NumPy

Q30. Donner la sortie exacte du code suivant.

```
a = [4, 8, 15, 16, 23, 42]
print(a[1], a[-2], a[2:4], a[3:], len(a))
b = a
b.append(7)
print(len(a))
t = "embedded"
print(t[0], t[2:5], t[-3:])
print(17 // 5, 17 % 5, 17 / 5, 3 ** 2)
```

Q31. Donner la sortie exacte du code suivant.

```
import numpy as np
A = np.arange(12).reshape(3, 4)
print(A.shape, A[2, 1], A[1], A[:, 3])
print(A.sum(axis=0), A.sum(axis=1))
print(A.T.shape, (A @ A.T).shape)
v = np.array([3.0, -4.0])
print(np.sqrt(np.sum(v ** 2)), v[v > 0])
print(np.linspace(2, 4, 5))
```

Q32. Écrire sans boucle une fonction `euclidean_norm_2d(X)` qui renvoie la norme euclidienne de chaque ligne (exercice 4 du TP 1). Que renvoie-t-elle pour $\begin{pmatrix} 0{,}5 & -1{,}2 & 4{,}5 \\ -3{,}2 & 1{,}9 & 2{,}7 \end{pmatrix}$?

Q33. Dans le TP 2, `x_train = np.linspace(0, 10, 51)`. Combien de points, quel pas ? Quelle est la forme de `np.vstack([np.ones(51), x_train]).T`, et que se passe-t-il si l'on oublie `.T` ?

Niveau 8. Régression linéaire

Q34. Données $x = (1, 2, 3, 4)$, $y = (2, 3, 5, 6)$, modèle $y = w_0 + w_1 x$. Calculer $\mathbf{X}^\top\mathbf{X}$, $\mathbf{X}^\top\mathbf{y}$, puis $\mathbf{w}$ par les équations normales. En déduire les prédictions, la RMSE sur ces points et la prédiction en $x = 6$.

Q35. Mêmes données, régression ridge avec $\lambda = 2$ appliquée comme dans le TP (`np.eye`, biais compris). Calculer $\mathbf{w}$ et comparer.

Q36. (a) Écrire la matrice $\mathbf{\Phi}$ d'une régression polynomiale de degré 2 pour $x = (0, 1, 2)$. (b) Combien de paramètres pour un degré D ? (c) Avec $\mathbf{w} = (-54;\ 69;\ -16;\ 1)$ en degré 3, prédire en $x = 5$ et $x = 10$. (d) Que devient la courbe quand λ passe de 0 à 100 ?

Q37. Valeurs vraies $y = (10, 12, 9, 15, 14)$, prédictions $\hat{y} = (11, 12, 7, 15, 12)$. Calculer la MSE et la RMSE.

Q38. Dans le TP 2 (jeu `diabetes`), la régression « à la main » et `LinearRegression` donnent la même RMSE, 56,94. Pourquoi ? Pourquoi la calcule-t-on sur le jeu de test ?

Niveau 9. Régression logistique

Q39. Modèle logistique $\mathbf{w} = (-1;\ 2;\ -1)$ sur $\phi(\mathbf{x}) = [1, x_1, x_2]$. Classer les points $(1, 0)$, $(0, 1)$, $(2, 1)$ et $(0{,}5;\ 0)$ avec les valeurs de σ. Donner l'équation de la frontière.

Q40. Points $(0, 1)$ et $(2, 2)$ de classe 1, $(1, 0)$ et $(3, 0)$ de classe 0. Partir de $\mathbf{w} = 0$ et faire un pas de descente de gradient avec $\eta = 0{,}2$ et le gradient $\mathbf{\Phi}^\top(\sigma(\mathbf{\Phi w}) - \mathbf{y})$. Classer les quatre points avec le nouveau $\mathbf{w}$.

Q41. `pred = [1,1,0,0,1,0,1,0]`, `y = [1,0,0,1,1,1,0,0]`. Que vaut `np.sum(pred - y)` ? Combien y a-t-il de faux positifs, de faux négatifs, d'erreurs ? Quelle proportion de bonnes réponses ? Même proportion pour 14 erreurs sur 200.

Q42. Pourquoi le TP code-t-il la sigmoïde avec `u = np.exp(-np.abs(a))` ? Que vaut $\sigma(-800)$?

Niveau 10. VRAI/FAUX, cours 3 à 6

Barème des séries d'entraînement 2026 : +1 par bonne réponse, −1 par mauvaise, 0 sans réponse. Répondre V ou F, puis justifier en une ligne (la justification sert à réviser, elle n'est pas lue au midterm).

Q43. (a) Classer un nouveau point par kNN coûte $O(dN)$, dominé par le calcul des distances. (b) Un arbre de décision peut représenter n'importe quelle fonction logique de ses attributs. (c) La construction gloutonne trouve toujours le plus petit arbre cohérent avec les exemples. (d) Un attribut qui identifie chaque exemple (numéro de série) est le meilleur test à la racine. (e) Une méthode à 92 % d'accuracy est forcément meilleure qu'une méthode à 80 %. (f) FPR $= 1 -$ spécificité. (g) Une AUC de 0,3 indique un attribut pire qu'un tirage au hasard. (h) Le jeu de validation sert à mesurer la performance finale du modèle.

Q44. (a) Le coût de k-means est $O(N \cdot K \cdot J \cdot d)$. (b) Le clustering hiérarchique ascendant exige de fixer le nombre de clusters à l'avance. (c) Single linkage et complete linkage donnent toujours la même suite de fusions. (d) DBSCAN isole des points de bruit sans qu'on fixe le nombre de clusters. (e) La PCA capte aussi les relations non linéaires entre variables. (f) Sans activation non linéaire, un réseau multicouche n'est pas plus puissant qu'une seule couche. (g) Ajouter des neurones cachés fait toujours baisser l'erreur de test. (h) Dans le cas d'usage du cours 5, la version int8 du classifieur a une meilleure accuracy que la version float32.

Q45. Avec ce barème, quelle est l'espérance de points d'une réponse donnée avec une probabilité p d'avoir raison ? Pour $p = 0{,}5,\ 0{,}7,\ 0{,}9$? Quelle règle en tirer ?

Niveau 11. kNN et coût des calculs

Q46. Un kNN dispose de $N = 2000$ exemples de dimension $d = 10$, avec $K = 7$. Distance euclidienne au carré. (a) Combien de multiplications pour classer un nouveau point ? (b) Combien de soustractions et d'additions ? (c) Prendre la racine carrée change-t-il les voisins choisis ? (d) Combien de multiplications avec la distance de Manhattan ? (e) Le système doit classer 100 points par seconde : combien de multiplications par seconde ?

Q47. Même kNN réparti sur $M = 4$ nœuds comme à la p. 6 de `03_Classification`. (a) Multiplications faites par chaque nœud ? (b) Parmi combien de candidats choisit-on les K voisins finaux ? (c) Le nombre total de multiplications change-t-il ? Qu'est-ce qui s'améliore ?

Q48. On regroupe les mêmes 2000 points par k-means avec $K = 7$ clusters et $J = 20$ itérations. Combien de multiplications pour les affectations (distance au carré) ? Comparer au kNN de la question précédente. Quelle variante du cours réduit ce coût, et comment ?

Niveau 12. Entropie

Q49. Calculer I en bits pour les proportions : (a) $\frac{1}{2}, \frac{1}{2}$; (b) quatre classes équiprobables ; (c) 0,9; 0,1 ; (d) 1; 0 ; (e) $\frac{1}{4}, \frac{1}{4}, \frac{1}{2}$.

Q50. Pari sur une pièce qui tombe sur face 80 % du temps. Quelle quantité d'information faut-il pour connaître l'issue ? Pourquoi est-ce moins qu'avec une pièce équilibrée ? (`03_Classification`, p. 19 ; quiz 03.5)

Q51. 1800 exemples, trois classes de 600. Un test à trois issues envoie dans chaque branche deux classes de 300. Un camarade calcule « $\log_2 3 - 3 \times 1$ ». Que vaut ce calcul et pourquoi est-il faux ? Donner le vrai gain.

Niveau 13. Arbre de décision

Données d'exercice : 12 compresseurs décrits par la vibration (O oui, N non), la température (B basse, M moyenne, H haute) et l'âge (J jeune, V vieux). Cible : panne dans l'année.

n°	Vib.	Temp.	Âge	Panne	n°	Vib.	Temp.	Âge	Panne
1	O	H	V	oui	7	N	H	V	non
2	O	H	J	oui	8	N	H	J	non
3	O	M	V	oui	9	N	M	V	oui
4	O	M	J	non	10	N	M	J	non
5	O	B	V	non	11	N	B	V	non
6	O	B	J	non	12	N	B	J	non

Q52. Calculer l'information nécessaire au départ, puis le gain des tests sur la vibration, la température et l'âge. Quel attribut tester à la racine ?

Q53. Terminer l'arbre : pour chaque branche impure, choisir le test suivant par le gain. Dessiner l'arbre. Classer les compresseurs (N, M, V) et (O, H, J).

Q54. On ajoute un numéro de série, différent pour chaque compresseur. Quel est son gain ? Faut-il le tester ? Combien d'instances distinctes et de fonctions booléennes ces trois attributs permettent-ils ?

Niveau 14. Matrice de confusion et ROC

Données d'exercice : un capteur mesure x sur 1500 pièces, 1000 normales et 500 défectueuses. Positif = défaut ; une pièce est déclarée défectueuse si $x \geq$ seuil.

Intervalle de x	$[0, 10)$	$[10, 20)$	$[20, 30)$	$[30, 40)$	$[40, 50]$
normales	400	300	200	80	20
défectueuses	10	40	100	150	200

Q55. Seuil 30 : donner TP, FN, FP, TN, la sensibilité, la spécificité, l'accuracy, la précision et le F_1.

Q56. Mêmes métriques (sensibilité, spécificité, FPR, accuracy) pour les seuils 10, 20 et 40. Quel seuil maximise l'accuracy ? Si l'on exige une sensibilité d'au moins 0,9, quel seuil choisir ?

Q57. Tracer la courbe ROC (seuils 0 à 50 et au-delà) et calculer l'AUC par les trapèzes. Comparer au hasard.

Q58. Deux classifieurs triviaux : « toujours défectueuse », « toujours normale ». Donner leur sensibilité, leur spécificité et leur accuracy. Quelle leçon (`03_Classification`, p. 27 et 41) ?

Q59. Sur le tableau du cours (`03_Classification`, p. 33, seuil 27 : $TP = 6200$, $FN = 3800$, $FP = 2500$, $TN = 7500$), les slides donnent sensibilité et spécificité. Calculer la précision et le F_1.

Niveau 15. Distances et k-means

Q60. Une distribution centrée en $M = (0, 0)$ a $\sigma_x = 1$ et $\sigma_y = 2$, sans corrélation. Points $P = (2, 0)$ et $Q = (0, 3)$. Distances euclidiennes et de Mahalanobis à M ; quel point est le plus proche selon chacune ?

Q61. Points $A(1, 1)$, $B(2, 1)$, $C(1, 2)$, $D(2, 3)$, $E(6, 5)$, $F(7, 5)$, $G(6, 6)$, $H(4, 4)$; centres initiaux $c_1 = (2, 2)$, $c_2 = (5, 5)$. Faire une itération de k-means (tableau des distances au carré). Dans quel sens chaque centre se déplace-t-il ? Faire la deuxième itération : l'algorithme s'arrête-t-il ?

Q62. Yinyang k-means. Pour un point x : borne supérieure $ub = 2{,}0$ vers son centre, qui se déplace de 0,3 ; borne inférieure $lb = 3{,}0$ vers un autre centre c_k. (a) c_k se déplace de 0,5 : faut-il calculer $d(x, c'_k)$? (b) Et s'il se déplace de 0,9 ?

Niveau 16. Clustering hiérarchique

Q63. Six points sur une droite : $a = 0$, $b = 1$, $c = 3$, $d = 7$, $e = 12$, $f = 13{,}5$. Clustering ascendant, single linkage. Donner la suite des fusions et leurs hauteurs, dessiner le dendrogramme. Combien de clusters avec une distance limite de 3 ? de 4,5 ? Quel point ressort comme anomalie à la limite 3 ?

Q64. Mêmes points en complete linkage. Suite des fusions ? La partition en deux clusters est-elle la même qu'en single linkage (type quiz 04.4) ? Expliquer par le point d.

Niveau 17. PCA

Q65. Points $(7,5)$, $(1,-1)$, $(5,1)$, $(3,3)$. Centrer, calculer $\boldsymbol{\Sigma}$ avec la convention $\frac{1}{N}$ de `04_Clustering` (p. 45), ses valeurs propres, la première composante principale, la part de variance décrite et les projections sur cette composante.

Q66. (a) Valeurs singulières de la matrice centrée de la question précédente, et lien avec les valeurs propres. (b) Sur iris (TP 3), les valeurs singulières des données centrées sont 25,09 ; 6,01 ; 3,42 ; 1,88. Combien de composantes faut-il pour décrire au moins 95 % de la variance, avec la formule du script `pca_iris.m` ?

Niveau 18. Cas d'usage : détection de chute

Q67. Avec les chiffres de `05_UseCase` (p. 6) : échantillons par axe et par fenêtre, valeurs par fenêtre pour trois axes, nombre d'essais, taille des jeux d'entraînement, de validation et de test.

Q68. Avec les matrices de confusion de la p. 15 : accuracy en float32 et en int8, sensibilité de la classe repos, précision de la classe chute. Que gagne-t-on et que perd-on avec int8 ?

Q69. Score d'anomalie $d(\mathbf{x}) = \min_k(\|\mathbf{x} - c_k\|_2 - r_k)$, en 2D pour simplifier : $c_1 = (0,0)$, $r_1 = 1$; $c_2 = (4,0)$, $r_2 = 0{,}5$; seuil d'anomalie 0,5. Scorer $(0{,}6;\ 0{,}8)$, $(2,0)$ et $(4;\ 0{,}3)$.

Q70. Normaliser $X = [2,4,6]$ avec la formule de la p. 10.

Niveau 19. Neurone et activations

Q71. Neurone à trois entrées : $\mathbf{x} = (2;\ -1;\ 0{,}5)$, $\mathbf{w} = (0{,}4;\ 0{,}3;\ -0{,}6)$, $b = 0{,}1$. Potentiel v, puis sortie avec `hardlim`, `purelin`, `logsig`, `tansig`, `satlin`, `satlins` et ReLU. Même question avec $b = -0{,}5$.

Q72. Vérifier la sortie `softmax` de `NN2a`, slide 5, pour l'entrée $(0;\ 1;\ -0{,}5;\ 0{,}5)$.

Niveau 20. Un pas de rétropropagation (type quiz 06.3)

Réseau 2-2-1, activation logistique ($a = 1$) partout, biais portés par une entrée constante 1. Entrées $x_1 = 1$, $x_2 = 0{,}5$; cible $d = 1$; pas $\eta = 0{,}5$; $E = \frac{1}{2}e^2$, convention de `NN4a`.

Neurone	biais	poids depuis x_1 ou h_1	poids depuis x_2 ou h_2
caché h_1	$w_{10} = 0{,}1$	$w_{11} = 0{,}4$	$w_{12} = -0{,}2$
caché h_2	$w_{20} = -0{,}3$	$w_{21} = 0{,}2$	$w_{22} = 0{,}6$
sortie y	$u_0 = 0{,}2$	$u_1 = 0{,}5$	$u_2 = -0{,}4$

Q73. Passe avant : v_{h1}, h_1, v_{h2}, h_2, v_y, y et l'erreur e.

Q74. Calculer $f'(v_y)$, puis $\frac{\partial y}{\partial u_0}$, $\frac{\partial y}{\partial u_1}$, $\frac{\partial y}{\partial u_2}$ (type quiz 06.2) et le gradient local δ_y.

Q75. Gradients locaux δ_{h1} et δ_{h2}, puis nouvelles valeurs de u_0, u_1, u_2, w_{11} et w_{22}. Recalculer y avec tous les poids mis à jour. Donner aussi les nouvelles valeurs de u_2 et w_{11} avec $E = e^2$.

Q76. Quiz 06.1 : pourquoi ne pas prendre $E = |e|$, ou simplement $E = e$?

Niveau 21. Vanishing gradient et généralisation

Q77. (a) Calculer $\sigma'(0)$, $\sigma'(2)$, $\sigma'(5)$ pour la logistique. (b) Majorer le facteur $\prod f'$ accumulé à travers 4 couches logistiques. (c) Dérivée de tanh en 0, de ReLU pour $v > 0$ et $v < 0$. (d) Expliquer le vanishing gradient et citer ce que `NN4a` (slides 33 et 37) en dit.

Q78. Erreur de validation par époque : 0,40 ; 0,31 ; 0,26 ; 0,24 ; 0,25 ; 0,23 ; 0,27 ; 0,30. (a) Avec la règle « arrêter à la première hausse », quels poids garde-t-on ? (b) Avec la pratique recommandée par `NN8` (slide 37) ? (c) Pourquoi l'erreur d'entraînement ne suffit-elle pas ?

Q79. 1000 exemples. (a) Tailles des trois jeux en 60 : 20 : 20 (`NN2a`, slide 44) et en 70 : 15 : 15 (`05_UseCase`). (b) Rôle de chaque jeu. (c) Un étudiant choisit le nombre de neurones cachés qui donne la plus petite erreur sur le jeu de test et annonce cette erreur : qu'est-ce qui ne va pas ?

Q80. Moment (`NN4a`, slide 35) : $\eta = 0{,}5$, $\delta_j = 0{,}1$, $y_i = 0{,}6$, correction précédente $\Delta w(n-1) = 0{,}02$, $\alpha = 0{,}9$. Calculer $\Delta w(n)$ avec et sans moment.

2. Corrigés

Niveau 1

Q1. (b) et (d). La slide range aussi communication et fusion d'informations dans « important » ; mémoire, puissance de calcul et temps de réponse sont « non critiques ». Source : `01_Intro`, slide 9

Q2. But (tâche spécifique contre large éventail), contraintes (mémoire, calcul, temps de réponse, consommation), interface (souvent absente ou minimale), durée de vie (souvent dix ans ou plus, contre quelques années), logiciel (OS temps réel ou pas d'OS, contre Windows, macOS, Linux). Source : `01_Intro`, slide 6

Q3. (a), (c), (e) : trait plein sur la slide. Maintenance prédictive, reconnaissance d'images et reconnaissance vocale sont en pointillés (généraliste ou embarqué) ; recommandation et trading ne sont pas encadrés. Source : `01_Intro`, slide 17

Q4. Rationalité : choisir la meilleure action pour atteindre un but, selon des critères à optimiser et avec les ressources disponibles ; formellement, maximiser l'utilité espérée (le monde est incertain). Le cours retient la colonne « rationnellement » (penser et agir) : approche d'ingénieur, but fixé, atteint avec le moins d'effort, de temps ou d'énergie. La voie naturelle n'est pas la meilleure : avions à ailes battantes, jambes contre roues et routes. Source : `01_Intro`, slides 11 et 14

Q5. (a) vrai. (b) faux : sous forme d'exemples, pas de lois, de règles ou de formules. (c) vrai. (d) faux : l'ellipse « Embedded AI » recoupe IA, ML et DL, elle n'est contenue dans aucun. Source : `01_Intro`, slide 18

Q6. Avec modèle : on sait que le circuit est linéaire, on connaît la forme de la fonction de transfert ; on mesure V_1, V_2 à plusieurs fréquences et on identifie R_1 à R_4, L, C (risque : modèle faux). Sans modèle : $V_2 = f(V_1(\omega))$ inconnue, seulement un tableau de mesures (questions : combien de données, comment en tirer une prédiction). Communes : précision et bruit de mesure. Même but : prédire V_2 pour tout V_1 et ω. Source : `01_Intro`, slides 20 et 21

Q7. (a), (c), (d), plus l'économie de bande passante. (b) est faux : la slide cite au contraire des ressources limitées face au cloud ; (e) n'est pas cité. Source : `01_Intro`, slide 29

Q8. Quantification : réduire la précision numérique des poids (par exemple FP32 vers int8) ; elle réduit la taille de *chaque* paramètre. Élagage : supprimer les poids ou neurones inutiles ; il réduit leur *nombre*. Les deux sont annoncés pour plus tard dans le semestre. Source : `01_Intro`, slide 28

Niveau 2

Q9. $2 \cdot 10^9 \times 0{,}34 = 0{,}68 \cdot 10^9$ Wh par jour. 0,68/0,85 = 0,8 tranche de 10 minutes, soit 8 minutes de consommation de la Hongrie. Source : `01_Intro`, slide 26

Q10. 62 318 800 kWh $\times 1000 = 6{,}23 \cdot 10^{10}$ Wh, soit à peu près la demi-journée de consommation hongroise citée ($6{,}1 \cdot 10^{10}$ Wh). Rapport 62 318 800/1 287 000 $\approx$ 48,4. Prix : 168 597/1 287 000 = 0,131 \$ par kWh, le tarif indiqué sur la slide. Source : `01_Intro`, slide 25

Q11. $10^6/20 = 50\,000$ cerveaux (le chiffre de la slide) ; $10^6/100 = 10\,000$ corps. Source : `02_Challenges`, p. 17

Q12. 1,5 semaine = 10,5 jours ; 10,5/2,5 = 4,2 fois plus long pour $10{,}76 - 6{,}16 = 4{,}6$ points d'erreur en moins. De ResNet101 (7 jours) à ResNet152 : 3,5 jours de plus pour $6{,}21 - 6{,}16 = 0{,}05$ point. Le gain décroît vite : c'est l'argument de la slide, un entraînement aussi long est hors de portée d'un appareil embarqué. Source : `02_Challenges`, p. 10

Niveau 3

Q13. $T(N) = O(F(N))$ s'il existe $c > 0$ et N_0 tels que $T(N) \leq cF(N)$ pour tout $N > N_0$. Avec $c = 4$: $3N^2+5N+2 \leq 4N^2 \iff N^2-5N-2 \geq 0$. Racine positive $(5 + \sqrt{33})/2 \approx 5{,}37$; vrai pour tout $N \geq 6$, donc $N_0 = 5$. D'autres couples conviennent (par exemple $c = 10$, $N_0 = 1$: $3N^2 + 5N + 2 \leq 3N^2 + 5N^2 + 2N^2$ pour $N \geq 1$). Source : `01_Intro`, slide 31

Q14.

N	force brute	moitiés $\lceil \log_2 N \rceil$	tiers $\lceil \log_3 N \rceil$
27	26	5	3
100	99	7	5

Pour 9 pièces : trois groupes de 3 ; on pèse le groupe 1 contre le groupe 2. Si un plateau monte, la fausse est dans ce groupe ; sinon dans le groupe 3. Il reste 3 pièces : on pèse la pièce 1 contre la pièce 2 ; la plus légère est la fausse, ou c'est la 3 en cas d'équilibre. Deux pesées, $\log_3 9 = 2$. Source : `01_Intro`, slide 32 ; méthode générale

Q15. Faux. $\log_2 N = \log_2 3 \cdot \log_3 N \approx 1{,}585 \log_3 N$: les deux ne diffèrent que d'une constante, que la notation O ignore. Même classe. La méthode par tiers fait bien moins de pesées en pratique (5 contre 7 pour $N = 100$) : la constante compte, mais pas pour O. Source : `01_Intro`, slides 32 et 35

Q16. Bulles : $N^2 = 10^6$. Fusion : $N \log_2 N \approx 9\,966$. Environ 100 fois moins pour la fusion. Mais la fusion demande $O(N)$ de mémoire en plus, le tri à bulles $O(1)$: sur un microcontrôleur très limité en RAM, on peut préférer le tri à bulles et payer en temps. Source : `01_Intro`, slide 34

Q17. Passe 1 : $3{,}9 > -2$ échange ; $3{,}9 > 1$ échange ; $3{,}9 < 7$; $7 < 12$; $12 > 5$ échange ; $12 > -2{,}37$ échange. Quatre échanges : $[-2;\ 1;\ 3{,}9;\ 7;\ 5;\ -2{,}37;\ 12]$. Le $-2{,}37$ recule d'une case par passe : il faut 6 passes avec échanges puis une 7e sans échange, soit 7 passes. Résultat : $[-2{,}37;\ -2;\ 1;\ 3{,}9;\ 5;\ 7;\ 12]$. Source : `01_Intro`, slide 34 ; vérifié par script

Niveau 4

Q18. (a) supervisé (sortie désirée connue). (b) non supervisé (clustering). (c) par renforcement (retour seulement à certaines étapes). (d) supervisé : chaque entrée (V_1, ω) a sa sortie mesurée V_2. Source : `02_Challenges`, p. 5 ; `01_Intro`, slide 21

Q19. (a) et (c). Arbre de décision et plus proche voisin sont typiquement supervisés. Source : `02_Challenges`, p. 8

Q20. L'entraînement est déjà long sur une grappe de GPU (ResNet152 : 1,5 semaine sur quatre M40) ; sur un appareil embarqué il serait bien plus long, voire impossible. On entraîne ailleurs et on déploie. Parfois on poursuit l'entraînement d'un modèle déjà entraîné avec de nouvelles données pour l'adapter à une situation qui change, ce qui n'est pas un entraînement depuis zéro. Source : `02_Challenges`, p. 10 et 11

Niveau 5

Q21. (a), (c), (d). (b) est faux : le cloud aggrave le temps réel et le temps de réaction ; c'est le mode local qui l'améliore. Source : `02_Challenges`, p. 24 et 27

Q22. Biais : la nationalité non néerlandaise était un facteur de risque. Transparence : l'agent qui révisait le dossier ne savait pas pourquoi le score était élevé. Responsabilité : les agents ne se sentaient pas responsables, la décision était attribuée au modèle. Dépendance excessive (over-reliance) : on suivait la suggestion. Conséquence : démission du gouvernement le 15 janvier 2021. Source : `02_Challenges`, p. 21 et 22

Q23. (a) sûreté (interférence et altération). (b) confiance (transparence). (c) gouvernance (contrôle réglementaire). (d) sûreté (décisions temps réel). (e) gouvernance (mise à jour et maintenance). Source : `02_Challenges`, p. 18 à 23

Q24. (a), (c), (d). Le GPU est orienté débit, pas latence. Source : `02_Challenges`, p. 29

Niveau 6

Q25. 640/0,1 = 6400. 640/5 = 128. 3,7/0,2 = 18,5 en énergie et 7700/282 $\approx$ 27,3 en surface. Source : `02_Challenges`, p. 33

Q26. (a) Calcul : $10^6 \times (3{,}7 + 0{,}9) = 4{,}6 \cdot 10^6$ pJ $= 4{,}6\ \mu$J. Mémoire : $10^6 \times 640$ pJ $= 640\ \mu$J. Total 644,6 μJ, dont 640/644,6 $\approx$ 99,3 % pour la DRAM. (b) 4,6 + 5 = 9,6 μJ, environ 67 fois moins. (c) $10^6 \times (0{,}2 + 0{,}03) = 0{,}23\ \mu$J, 20 fois moins qu'en FP32. (d) 644,6 μJ $\times$ 10 $\times$ 3600 $\approx$ 23,2 J. Source : chiffres `02_Challenges` p. 33 ; méthode générale

Q27. $V/2$: $P \times 1/4$. $f/2$: $P \times 1/2$. Les deux : $P \times 1/8$. De 1,2 à 1,0 V : $(1{,}0/1{,}2)^2 \approx 0{,}69$, soit 31 % de moins. Source : formule `02_Challenges` p. 28 ; calcul général

Q28. (a) 1 bit de signe, 5 d'exposant, 10 de mantisse, 16 au total. (b) $2^7 - 1 = 127$. (c) Non : 15 bits de magnitude donnent au plus $2^{15} - 1 = 32\,767$; $6 \cdot 10^4$ correspond à 16 bits sans signe ($2^{16} - 1 = 65\,535$). À l'examen, citer la slide et signaler l'écart. Source : `02_Challenges`, p. 32

Q29. VGG16 : FP32 $134{,}2 \times 4 = 536{,}8$ Mo ; FP16 268,4 Mo ; int8 134,2 Mo. ResNetV1 50 : $25{,}6 \times 4 = 102{,}4$ Mo $= 102{,}4 \cdot 10^6 / 2^{20} \approx 97{,}7$ Mio : c'est exactement la valeur de la slide, qui compte donc en Mio pour cette ligne (de même VGG16 : 511,9 Mio pour 512,2). Source : `02_Challenges`, p. 13 ; méthode générale

Niveau 7

Q30. Sortie obtenue :

```
8 23 [15, 16] [16, 23, 42] 6
7
e bed ded
3 2 3.4 9
```

Piège : `b = a` ne copie pas la liste, les deux noms désignent le même objet ; ajouter à `b` allonge `a`. `a[2:4]` s'arrête avant l'indice 4. Source : TP 1, cellules 16 à 41

Q31. Sortie obtenue :

```
(3, 4) 9 [4 5 6 7] [ 3  7 11]
[12 15 18 21] [ 6 22 38]
(4, 3) (3, 3)
5.0 [3.]
[2.  2.5 3.  3.5 4. ]
```

`A` vaut $[[0,1,2,3],[4,5,6,7],[8,9,10,11]]$; `axis=0` somme chaque colonne, `axis=1` chaque ligne ; $(3 \times 4)(4 \times 3)$ donne 3×3 ; pas de `linspace(2, 4, 5)` : $(4-2)/4 = 0{,}5$. Source : TP 1, cellules 76 à 125

Q32. `return np.sqrt(np.sum(X ** 2, axis=1))` (ou `np.linalg.norm(X, axis=1)`). Résultat : [4,684; 4,598], car $0{,}25+1{,}44+20{,}25 = 21{,}94$ et $\sqrt{21{,}94} \approx 4{,}684$; $10{,}24 + 3{,}61 + 7{,}29 = 21{,}14$ et $\sqrt{21{,}14} \approx 4{,}598$. Source : TP 1, cellule 133

Q33. 51 points, pas $10/50 = 0{,}2$. Forme $(51, 2)$: une ligne par exemple, une colonne de 1 puis les x. Sans `.T`, la forme est $(2, 51)$ et `X.T @ X` n'est plus la bonne matrice 2×2 ($(2 \times 51)^\top$ fois (2×51) donne du 51×51). Source : TP 2, cellules 1 à 4

Niveau 8

Q34. $\mathbf{X}^\top\mathbf{X} = \begin{pmatrix} 4 & 10 \\ 10 & 30 \end{pmatrix}$ ($N = 4$, $\sum x = 10$, $\sum x^2 = 30$) ; $\mathbf{X}^\top\mathbf{y} = (16;\ 47)$ ($\sum y = 16$, $\sum xy = 2 + 6 + 15 + 24 = 47$). Déterminant $120 - 100 = 20$. $w_0 = (30{\times}16 - 10{\times}47)/20 = 10/20 = 0{,}5$; $w_1 = (-10{\times}16 + 4{\times}47)/20 = 28/20 = 1{,}4$. Prédictions 1,9; 3,3; 4,7; 6,1 ; résidus 0,1; −0,3; 0,3; −0,1 ; somme des carrés 0,2 ; MSE 0,05 ; RMSE $\sqrt{0{,}05} \approx 0{,}224$. En $x = 6$: $0{,}5 + 1{,}4 \times 6 = 8{,}9$. Source : TP 2, cellule 3 ; vérifié par script

Q35. $\mathbf{X}^\top\mathbf{X} + 2\mathbf{I} = \begin{pmatrix} 6 & 10 \\ 10 & 32 \end{pmatrix}$, déterminant $192 - 100 = 92$. $w_0 = (32{\times}16 - 10{\times}47)/92 = 42/92 \approx 0{,}457$; $w_1 = (-10 \times 16 + 6 \times 47)/92 = 122/92 \approx 1{,}326$. Les deux poids diminuent (0,5 vers 0,457 et 1,4 vers 1,326) : la pénalité rétrécit $\mathbf{w}$ vers 0, y compris le biais puisque `np.eye` le régularise. Source : TP 2, cellule 9

Q36. (a) $\mathbf{\Phi} = \begin{pmatrix} 1 & 0 & 0 \\ 1 & 1 & 1 \\ 1 & 2 & 4 \end{pmatrix}$. (b) $D + 1$. (c) $y(5) = -54 + 345 - 400 + 125 = 16$, qui vaut bien $(5-9)(5-6)(5-1) = 16$; $y(10) = -54 + 690 - 1600 + 1000 = 36 = 1{\times}4{\times}9$. (d) Plus λ grandit, plus les poids rétrécissent et plus la courbe s'aplatit ; avec $\lambda = 100$ elle ne suit plus les données (sous-apprentissage). Source : TP 2, cellules 5 à 11 ; (d) rappel général

Q37. Erreurs $-1;\ 0;\ 2;\ 0;\ 2$; carrés $1;\ 0;\ 4;\ 0;\ 4$; MSE $9/5 = 1{,}8$; RMSE $\sqrt{1{,}8} \approx 1{,}342$. Source : formule du TP 2, cellule 15

Q38. Les deux résolvent le même problème des moindres carrés sur les mêmes données ; `LinearRegression` ajoute d'elle-même l'ordonnée à l'origine, comme la colonne de 1 du calcul manuel. Les RMSE diffèrent au dernier chiffre (56,94023984486523 contre 56,940239844865225) à cause des arrondis. On évalue sur le test pour mesurer la généralisation à des données non vues, but du ML. Source : TP 2, cellules 13 à 16 ; `02_Challenges` p. 6 et 7

Niveau 9

Q39. $a = -1 + 2x_1 - x_2$. $(1,0)$: $a = 1$, $\sigma = 0{,}731$, classe 1. $(0,1)$: $a = -2$, $\sigma = 0{,}119$, classe 0. $(2,1)$: $a = 2$, $\sigma = 0{,}881$, classe 1. $(0{,}5;\ 0)$: $a = 0$, $\sigma = 0{,}5$ exactement, sur la frontière ; avec la règle du TP (`> 0.5`), classe 0. Frontière : $2x_1 - x_2 - 1 = 0$, soit $x_2 = 2x_1 - 1$. Source : TP 2, cellules 21 à 23

Q40. Lignes de $\mathbf{\Phi}$: $[1,0,1]$, $[1,1,0]$, $[1,2,2]$, $[1,3,0]$; $\mathbf{y} = (1,0,1,0)$. En $\mathbf{w} = 0$: $\sigma = 0{,}5$ partout, $\sigma - y = (-0{,}5;\ 0{,}5;\ -0{,}5;\ 0{,}5)$. Gradient : biais 0 ; x_1 : $0 + 0{,}5 - 1 + 1{,}5 = 1$; x_2 : $-0{,}5 + 0 - 1 + 0 = -1{,}5$. Nouveau $\mathbf{w} = 0 - 0{,}2 \times (0;\ 1;\ -1{,}5) = (0;\ -0{,}2;\ 0{,}3)$. Scores a : $0{,}3$; $-0{,}2$; $0{,}2$; $-0{,}6$, donc classes $1, 0, 1, 0$: tout est juste après un pas. La perte passe de $4 \ln 2 \approx 2{,}773$ à $2{,}188$. Source : TP 2, cellule 23 ; vérifié par script

Q41. `pred - y` $= (0, 1, 0, -1, 0, -1, 1, 0)$, somme 0. Faux positifs (prédit 1, vrai 0) : positions 2 et 7, soit 2. Faux négatifs (prédit 0, vrai 1) : positions 4 et 6, soit 2. Erreurs : 4, et `np.sum(pred != y)` donne bien 4. Bonnes réponses $4/8 = 50$ %. Pour 14 erreurs sur 200 : $186/200 = 93$ %. Source : TP 2, cellule 23 (ligne `num_errs`) ; vocabulaire général

Q42. Pour éviter le débordement : avec $1/(1+e^{-a})$, $a = -800$ demande e^{800}, qui dépasse le plus grand float64 (`inf`, avec avertissement). La version du TP ne calcule que $e^{-|a|} \leq 1$. $\sigma(-800)$ vaut 0 en float64 (la vraie valeur, environ e^{-800}, est trop petite pour être représentée). Source : TP 2, cellule 22 ; vérifié avec NumPy

Niveau 10

Q43. (a) V : $O(dN)$, `03_Classification` p. 6. (b) V : expressivité complète, au prix d'une taille parfois exponentielle, p. 11. (c) F : le plus petit arbre est en général intraitable ; l'algorithme glouton cherche un optimum local à chaque nœud, p. 13 et 14. (d) F : son gain est maximal sur l'entraînement mais l'arbre ne généralise pas, p. 26. (e) F : l'accuracy dépend des proportions de classes du jeu de test (exemple de la prostate, B à 92 % est inutile), p. 41. (f) V : $\frac{FP}{FP+TN}$, p. 39. (g) V : $< 0{,}5$ est pire que le hasard, p. 50. (h) F : c'est le rôle du jeu de test, indépendant ; la validation sert à décider l'arrêt, p. 31 et 32.

Q44. (a) V : `04_Clustering` p. 8. (b) F : on coupe le dendrogramme où l'on veut, p. 28. (c) F : les critères peuvent donner des résultats différents, p. 27 (voir Q64). (d) V : p. 34. (e) F : relations linéaires seulement, p. 48. (f) V : `NN4a`, slide 4. (g) F : l'erreur d'entraînement baisse toujours, l'erreur de test baisse puis remonte, slide 47. (h) F : 552 contre 555 bonnes réponses sur 561 (`05_UseCase`, p. 15).

Q45. Espérance $= p \times 1 + (1-p) \times (-1) = 2p - 1$: 0 pour $p = 0{,}5$, 0,4 pour 0,7, 0,8 pour 0,9. Une réponse au hasard ne rapporte rien en moyenne et ajoute du risque : ne répondre que si l'on est nettement plus sûr qu'à une chance sur deux. Source : barème des séries 2026, fiche `CLAUDE.md`

Niveau 11

Q46. (a) d multiplications par exemple, soit $Nd = 2000 \times 10 = 20\,000$. (b) 20 000 soustractions et $N(d-1) = 18\,000$ additions. (c) Non : la racine est croissante, l'ordre des distances ne change pas ; on l'évite. (d) Aucune : $|x_i - y_i|$ ne demande qu'une soustraction et une valeur absolue. (e) $100 \times 20\,000 = 2 \cdot 10^6$ multiplications par seconde. Le choix des $K = 7$ plus proches ne demande que des comparaisons. Source : `03_Classification`, p. 6 ; comptage : rappel général

Q47. (a) Chaque nœud a 500 exemples : $500 \times 10 = 5000$ multiplications. (b) Parmi $MK = 4 \times 7 = 28$ candidats. (c) Le total reste 20 000 ; c'est le *temps* qui est divisé par environ 4, les nœuds calculant en parallèle, et chaque nœud a moins de mémoire à porter. Source : `03_Classification`, p. 6

Q48. $NKdJ = 2000 \times 7 \times 10 \times 20 = 2{,}8 \cdot 10^6$ multiplications, 140 fois le classement d'un point par kNN. La partie critique est NKd à chaque itération. Yinyang k-means évite la plupart de ces distances grâce à l'inégalité triangulaire (bornes supérieure et inférieure ; seuls les K déplacements de centres sont recalculés à coup sûr). Source : `04_Clustering`, p. 8 à 14

Niveau 12

Q49. (a) 1 bit. (b) $-4 \times \frac{1}{4}\log_2\frac{1}{4} = 2$ bits. (c) $-0{,}9\log_2 0{,}9 - 0{,}1\log_2 0{,}1 = 0{,}137 + 0{,}332 = 0{,}469$ bit. (d) 0, avec $0 \log 0 = 0$. (e) $\frac{1}{4}\times 2 + \frac{1}{4}\times 2 + \frac{1}{2}\times 1 = 1{,}5$ bit. Source : `03_Classification`, p. 17 et 25

Q50. $I(0{,}8;\ 0{,}2) = 0{,}8 \times 0{,}322 + 0{,}2 \times 2{,}322 = 0{,}722$ bit, contre 1 bit pour la pièce équilibrée (écart 0,278). On sait déjà en partie ce qui va sortir : l'issue est moins incertaine, l'information qui la révèle vaut moins. Pièce à deux faces : 0 bit. Source : `03_Classification`, p. 19 ; quiz 03.5

Q51. $\log_2 3 - 3 = 1{,}585 - 3 = -1{,}415$ bit : un gain négatif est impossible. L'erreur est d'additionner les besoins des branches sans les pondérer. Chaque branche porte 600/1800 $= \frac{1}{3}$ des exemples et demande 1 bit : reste $= 3 \times \frac{1}{3} \times 1 = 1$ bit, gain $= 1{,}585 - 1 = 0{,}585$ bit. Source : même piège que `03_Classification`, p. 22 ; vérifié par script

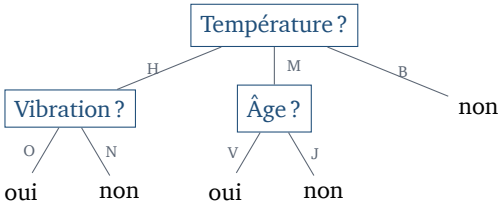
Niveau 13

Q52. 4 pannes sur 12 : $I(\frac{1}{3}, \frac{2}{3}) = 0{,}918$ bit.

Test	Branches (pannes, sans panne)	Reste	Gain
Vibration	O (3, 3) ; N (1, 5)	$\frac{1}{2} \times 1 + \frac{1}{2} \times 0{,}650 = 0{,}825$	0,093
Température	H (2, 2) ; M (2, 2) ; B (0, 4)	$\frac{4}{12} + \frac{4}{12} + 0 = 0{,}667$	0,252
Âge	V (3, 3) ; J (1, 5)	0,825	0,093

avec $I(\frac{1}{6}, \frac{5}{6}) = 0{,}650$. Racine : la **température**. Source : formules de `03_Classification`, p. 24 ; vérifié par script

Q53. Branche B : 4 sans panne, feuille « non ». Branche H (n°s 1, 2, 7, 8) : la vibration sépare parfaitement (O : 2 pannes ; N : 2 sans panne), gain 1 bit ; l'âge laisse (1, 1) et (1, 1), gain 0. Branche M (3, 4, 9, 10) : l'âge sépare parfaitement (V : 2 pannes ; J : 2 sans panne), gain 1 ; la vibration, gain 0.



(N, M, V) : température M, âge V, **panne**. (O, H, J) : température H, vibration O, **panne**. Le test du second niveau change selon la branche : chaque nœud choisit son propre meilleur attribut (glouton). Source : `03_Classification`, p. 13 à 16

Q54. Chaque compresseur forme sa propre branche, pure : reste 0, gain = 0,918 bit, le maximum. L'algorithme le choisirait, mais l'arbre ne ferait que mémoriser les 12 exemples et ne classerait aucun compresseur nouveau : à rejeter. Instances : $2 \times 3 \times 2 = 12$ (le tableau les contient toutes, une fois chacune) ; fonctions : $2^{12} = 4096$. Source : `03_Classification`, p. 12 et 26 ; comptage : rappel général

Niveau 14

Q55. Au-dessus de 30 : $150 + 200 = 350$ défectueuses (TP), $80 + 20 = 100$ normales (FP). En dessous : $FN = 150$, $TN = 900$. Total 1500. Sensibilité $350/500 = 0{,}70$; spécificité $900/1000 = 0{,}90$; accuracy $1250/1500 = 0{,}833$; précision $350/450 = 0{,}778$; $F_1 = 2 \times 0{,}778 \times 0{,}7/1{,}478 = 0{,}737$. Source : `03_Classification`, p. 39 ; vérifié par script

Q56.

Seuil	TP	FP	Sensibilité	Spécificité	FPR	Accuracy
10	490	600	0,98	0,40	0,60	0,593
20	450	300	0,90	0,70	0,30	0,767
30	350	100	0,70	0,90	0,10	0,833
40	200	20	0,40	0,98	0,02	0,787

Accuracy maximale au seuil 30. Sensibilité $\geq 0{,}9$: seuils 10 et 20 ; le seuil 20 garde la meilleure spécificité (0,70). Monter le seuil échange de la sensibilité contre de la spécificité.

Q57. Points (FPR, TPR) : $(0, 0)$, (0,02 ; 0,4), (0,1 ; 0,7), (0,3 ; 0,9), (0,6 ; 0,98), $(1, 1)$, du seuil « au-delà de 50 » au seuil 0. Trapèzes : $0{,}004 + 0{,}044 + 0{,}16 + 0{,}282 + 0{,}396 = 0{,}886$. Nettement au-dessus de 0,5 (hasard, diagonale) : le capteur est informatif, sans être idéal (1). Source : `03_Classification`, p. 42 à 51 ; vérifié par script

Q58. « Toujours défectueuse » : sensibilité 1, spécificité 0, accuracy $500/1500 = 0{,}333$. « Toujours normale » : sensibilité 0, spécificité 1, accuracy $1000/1500 = 0{,}667$. Le second ne détecte aucun défaut et a pourtant 0,667 d'accuracy : avec des classes déséquilibrées, l'accuracy seule trompe ; il faut sensibilité et spécificité, ou le F_1. Source : `03_Classification`, p. 27 et 41

Q59. Précision $6200/(6200 + 2500) = 0{,}713$; sensibilité 0,62 ; $F_1 = 2 \times 0{,}713 \times 0{,}62/1{,}333 = 0{,}663$. Source : `03_Classification`, p. 39 et 46

Niveau 15

Q60. Euclidienne : $d(M,P) = 2$, $d(M,Q) = 3$, P plus proche. Mahalanobis : $d(M,P) = 2/1 = 2$, $d(M,Q) = 3/2 = 1{,}5$, Q plus proche : un écart de 3 le long d'un axe où l'écart-type vaut 2 est moins inhabituel qu'un écart de 2 où il vaut 1. Source : `04_Clustering`, p. 6

Q61.

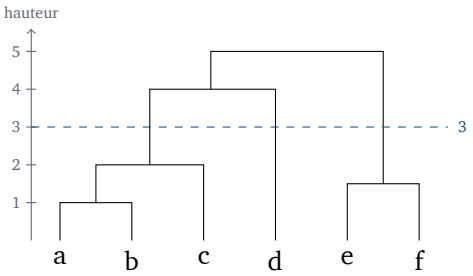
	A	B	C	D	E	F	G	H
d^2 à $c_1 = (2,2)$	2	1	1	1	25	34	32	8
d^2 à $c_2 = (5,5)$	32	25	25	13	1	4	2	2
affectation	1	1	1	1	2	2	2	2

$c_1' = \left(\frac{1+2+1+2}{4}, \frac{1+1+2+3}{4}\right) = (1{,}5;\ 1{,}75)$; $c_2' = \left(\frac{6+7+6+4}{4}, \frac{5+5+6+4}{4}\right) = (5{,}75;\ 5)$. Déplacements : c_1 de $(-0{,}5;\ -0{,}25)$, vers le bas et la gauche ; c_2 de $(+0{,}75;\ 0)$, vers la droite. Deuxième itération : H reste à c_2 ($d^2 = 4{,}06$ contre $11{,}31$), aucun point ne change de cluster, les centres ne bougent plus : arrêt. Source : `04_Clustering`, p. 8 et 9 ; vérifié par script

Q62. $ub' = 2{,}0 + 0{,}3 = 2{,}3$. (a) $lb' = 3{,}0 - 0{,}5 = 2{,}5 > 2{,}3$: c_k' ne peut pas être plus proche, on saute le calcul. (b) $lb' = 3{,}0 - 0{,}9 = 2{,}1 < 2{,}3$: le test ne conclut pas, il faut calculer $d(x, c_k')$. Source : `04_Clustering`, p. 12 et 13

Niveau 16

Q63. Distances successives : a-b 1, b-c 2, c-d 4, d-e 5, e-f 1,5. Single linkage : $\{a, b\}$ à 1 ; $\{e, f\}$ à 1,5 ; $\{a, b, c\}$ à 2 ; $\{a, b, c, d\}$ à 4 ; tout à 5.



Limite 3 : l'horizontale coupe 3 traits, clusters $\{a, b, c\}$, $\{d\}$, $\{e, f\}$; d, seul, est l'anomalie. Limite 4,5 : 2 clusters, $\{a, b, c, d\}$ et $\{e, f\}$. Source : `04_Clustering`, p. 15 à 24 ; vérifié par script

Q64. Complete linkage : $\{a, b\}$ à 1 ; $\{e, f\}$ à 1,5 ; $\{a, b, c\}$ à $\max(3, 2) = 3$; puis d : vers $\{a, b, c\}$, $\max = 7$; vers $\{e, f\}$, $\max = 6{,}5$; donc $\{d, e, f\}$ à 6,5 ; tout à 13,5. Partition en deux : $\{a, b, c\}$ et $\{d, e, f\}$, contre $\{a, b, c, d\}$ et $\{e, f\}$ en single linkage. Le point d est à 4 de c et à 5 de e (le minimum le rattache à gauche) mais à 7 de a et à 6,5 de f (le maximum le rattache à droite). Le résultat final dépend du critère. Source : `04_Clustering`, p. 26 et 27 ; vérifié par script

Niveau 17

Q65. Moyenne $(4,2)$; centrés $(3,3)$, $(-3,-3)$, $(1,-1)$, $(-1,1)$. $\Sigma_{xx} = (9+9+1+1)/4 = 5$, $\Sigma_{yy} = 5$, $\Sigma_{xy} = (9+9-1-1)/4 = 4$. $\lambda^2 - 10\lambda + 9 = 0$: $\lambda_1 = 9$, $\lambda_2 = 1$. Pour λ_1 : $(5-9)u_x + 4u_y = 0$, d'où $\mathbf{u}_1 = (1,1)/\sqrt{2}$. Variance décrite $9/10 = 90\,\%$. Projections $\mathbf{x}_{(st)}\mathbf{u}_1$: $6/\sqrt{2} = 4{,}243$; $-4{,}243$; 0 ; 0. Source : `04_Clustering`, p. 44 à 47 ; vérifié par script

Q66. (a) $s = (6,2)$; $s_i^2/N = 36/4 = 9$ et $4/4 = 1$: les valeurs propres. Variance cumulée du TP : $36/40 = 0{,}9$ puis 1. (b) s^2 : 629,5 ; 36,1 ; 11,7 ; 3,5 ; total 680,8. Cumul : 92,5 % ; 97,8 % ; 99,5 % ; 100 %. Deux composantes suffisent pour 95 %. Source : TP 3, `pca_iris.m` ; valeurs recalculées sur `irisdata.txt`

Niveau 18

Q67. $62{,}5 \times 2 = 125$ échantillons par axe, 375 valeurs pour trois axes. $7200/2 = 3600$ essais ; $0{,}70 \times 3600 = 2520$ en entraînement, 540 en validation, 540 en test. Source : `05_UseCase`, p. 6

Q68. Accuracy float32 $(187 + 183 + 185)/561 = 555/561 = 0{,}989$; int8 $552/561 = 0{,}984$. Sensibilité du repos (ligne) : $183/187 = 0{,}979$, puis $181/187 = 0{,}968$. Précision de la chute (colonne) : $187/189 = 0{,}989$, puis $187/190 = 0{,}984$. Aucune chute manquée dans les deux cas. int8 : mémoire des poids divisée par 4 et calcul entier moins coûteux (`02_Challenges`, p. 33), pour 3 erreurs de plus sur 561. Source : `05_UseCase`, p. 15 ; vérifié par script

Q69. $(0{,}6;\ 0{,}8)$: $\|\mathbf{x} - c_1\| = 1$, score $1 - 1 = 0$; $\|\mathbf{x} - c_2\| = \sqrt{3{,}4^2 + 0{,}8^2} = 3{,}493$, score 2,993 ; $d = 0$, normal (sur la frontière du cluster 1). $(2,0)$: scores $2 - 1 = 1$ et $2 - 0{,}5 = 1{,}5$; $d = 1 > 0{,}5$, **anomalie**. $(4;\ 0{,}3)$: scores 3,011 et $0{,}3 - 0{,}5 = -0{,}2$; $d = -0{,}2$, normal. Source : `05_UseCase`, p. 16 ; vérifié par script

Q70. Moyenne 4 ; std $= \sqrt{(4+0+4)/3} = 1{,}633$ (division par N) ; normalisé $(-1{,}225;\ 0;\ 1{,}225)$. Source : `05_UseCase`, p. 10

Niveau 19

Q71. $\mathbf{wx} = 0{,}8 - 0{,}3 - 0{,}3 = 0{,}2$.

b ; v	hardlim	purelin	logsig	tansig	satlin	satlins	ReLU
0,1 ; 0,3	1	0,3	0,5744	0,2913	0,3	0,3	0,3
−0,5 ; −0,3	0	−0,3	0,4256	−0,2913	0	−0,3	0

$\sigma(-v) = 1 - \sigma(v)$ et tanh est impaire : la seconde ligne se déduit de la première. Source : NN2a, slides 3 à 5 ; ReLU : rappel général

Q72. $e^0 = 1$, $e^1 = 2{,}718$, $e^{-0{,}5} = 0{,}607$, $e^{0{,}5} = 1{,}649$; somme 5,973. Sorties : 0,167 ; 0,455 ; 0,102 ; 0,276, soit les 0,17 ; 0,46 ; 0,1 ; 0,28 de la slide, de somme 1. Source : NN2a, slide 5

Niveau 20

Q73. $v_{h1} = 0{,}1 + 0{,}4 \times 1 - 0{,}2 \times 0{,}5 = 0{,}4$, $h_1 = \sigma(0{,}4) = 0{,}5987$. $v_{h2} = -0{,}3 + 0{,}2 + 0{,}6 \times 0{,}5 = 0{,}2$, $h_2 = 0{,}5498$. $v_y = 0{,}2 + 0{,}5 \times 0{,}5987 - 0{,}4 \times 0{,}5498 = 0{,}2794$, $y = 0{,}5694$, $e = 1 - 0{,}5694 = 0{,}4306$. Source : NN2a, slide 3 ; vérifié par script

Q74. $f'(v_y) = y(1-y) = 0{,}5694 \times 0{,}4306 = 0{,}2452$. $\dfrac{\partial y}{\partial u_i} = f'(v_y) \times$ (entrée portée par u_i) : $\dfrac{\partial y}{\partial u_0} = 0{,}2452$; $\dfrac{\partial y}{\partial u_1} = 0{,}2452 \times 0{,}5987 = 0{,}1468$; $\dfrac{\partial y}{\partial u_2} = 0{,}2452 \times 0{,}5498 = 0{,}1348$. $\delta_y = e\, f'(v_y) = 0{,}4306 \times 0{,}2452 = 0{,}1056$. Source : NN4a, slides 10 et 15

Q75. $\delta_{h1} = h_1(1-h_1)\,u_1\,\delta_y = 0{,}2403 \times 0{,}5 \times 0{,}1056 = 0{,}01268$; $\delta_{h2} = 0{,}2475 \times (-0{,}4) \times 0{,}1056 = -0{,}01045$ (anciens poids u_1, u_2).

Poids	Correction $\eta\,\delta \times$ entrée	Nouvelle valeur
u_0	$0{,}5 \times 0{,}1056 \times 1 = 0{,}0528$	0,2528
u_1	$0{,}5 \times 0{,}1056 \times 0{,}5987 = 0{,}0316$	0,5316
u_2	$0{,}5 \times 0{,}1056 \times 0{,}5498 = 0{,}0290$	−0,3710
w_{11}	$0{,}5 \times 0{,}01268 \times 1 = 0{,}0063$	0,4063
w_{22}	$0{,}5 \times (-0{,}01045) \times 0{,}5 = -0{,}0026$	0,5974

Les autres : $w_{10} = 0{,}1063$, $w_{12} = -0{,}1968$, $w_{20} = -0{,}3052$, $w_{21} = 0{,}1948$. Après le pas, $y = 0{,}5915$: l'erreur passe de 0,4306 à 0,4085. Avec $E = e^2$, tous les δ doublent : $u_2 = -0{,}4 + 0{,}5 \times 0{,}2112 \times 0{,}5498 = -0{,}3420$ et $w_{11} = 0{,}4 + 0{,}5 \times 0{,}02537 = 0{,}4127$ (y après le pas : 0,6132). Source : NN4a, slides 11 à 15 ; vérifié par script

> **Piège**
>
> $\delta_{h2} < 0$ parce que $u_2 < 0$: pour faire monter y, le réseau fait *baisser* h_2. Le gradient caché utilise les poids de sortie *avant* leur mise à jour.

Q76. Avec $E = e$, minimiser pousse e vers $-\infty$ (sortie bien au-dessus de la cible) et des erreurs de signes opposés se compensent sur plusieurs exemples. $E = |e|$ mesure bien l'écart mais n'est pas dérivable en $e = 0$, et sa dérivée garde la même amplitude (± 1) quelle que soit l'erreur : la correction ne ralentit pas près de la cible. $E = e^2$ (ou $\frac{1}{2}e^2$) est dérivable partout, sa dérivée est proportionnelle à l'erreur. Source : rappel général ; règle delta, NN2a, slide 16

Niveau 21

Q77. (a) $\sigma'(0) = 0{,}25$ (son maximum) ; $\sigma'(2) = 0{,}105$; $\sigma'(5) = 0{,}0066$. (b) Au plus $0{,}25^4 = 0{,}0039$: le gradient qui arrive à la première couche est au moins 256 fois plus petit, davantage si les neurones saturent. (c) $\tanh'(0) = 1$; ReLU : 1 pour $v > 0$, 0 pour $v < 0$. (d) La rétropropagation multiplie les dérivées des couches traversées ; si elles sont petites (sigmoïdes saturées par de grands poids), le gradient s'évanouit et les premières couches n'apprennent presque plus. `NN4a` : « paralysie du réseau », gradients presque nuls avec des sigmoïdes et de très grands poids, apprentissage presque arrêté (slide 33) ; la rétropropagation résiliente n'utilise que le signe de la dérivée (slide 37). Initialiser des poids pas trop grands évite la saturation (slide 29). Courbes et ReLU : `fiche-midterm-practice.pdf`.

Q78. (a) L'erreur monte pour la première fois à l'époque 5 (0,25 après 0,24) : on garde les poids de l'époque 4, erreur 0,24. (b) Entraîner plus loin en sauvegardant les poids à chaque époque, puis revenir à l'époque d'erreur de validation minimale : époque 6, 0,23 (backtracking). (c) L'erreur d'entraînement baisse toujours avec les époques ; seule une erreur sur des données non apprises révèle le surapprentissage. Source : `NN8`, slides 35 à 37 ; `03_Classification`, p. 31

Q79. (a) 600, 200, 200 ; 700, 150, 150. (b) Entraînement : ajuster les poids. Validation : choisir les hyperparamètres et décider l'arrêt. Test : estimer une seule fois, à la fin, la performance sur des données jamais utilisées. (c) Le test a servi à choisir : il joue le rôle d'une validation, et l'erreur annoncée est trop optimiste. Il faut choisir sur la validation et garder le test pour la fin. Source : `NN2a`, slide 44 ; `NN8`, slide 33 ; `03_Classification`, p. 32

Q80. Sans moment : $\eta\,\delta_j\,y_i = 0{,}5 \times 0{,}1 \times 0{,}6 = 0{,}03$. Avec : $0{,}9 \times 0{,}02 + 0{,}03 = 0{,}048$. Le moment prolonge la direction précédente et accélère dans une descente régulière. Source : `NN4a`, slide 35 ; vérifié par script