Sujets blancs rédigés par nous à partir des supports 2026 du cours ; ce ne sont pas des sujets officiels. Corrigés non officiels, calculs vérifiés par `exams/latex/calc_examens_blancs_embai.py`.

EMBAI, midterm blanc 1

50 points, 20 requis pour la signature. Calcul exigé dans les exercices 2 à 6 : un résultat sans calcul ne rapporte rien. Arrondir à 4 décimales.

Exercice 1 (10 points)

Entourer VRAI ou FAUX. Bonne réponse +1, mauvaise réponse −1, sans réponse 0 ; un total négatif est ramené à 0. Aucune justification n'est lue.

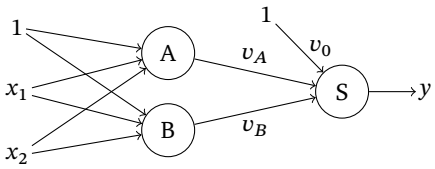
Type : bloc VRAI/FAUX des séries d'entraînement 2026 et des annales

a	Pour N grand, un algorithme en $O(N \log_2 N)$ demande moins de calcul qu'un algorithme en $O(N^2)$.	VRAI FAUX
b	Un classifieur binaire qui atteint 95 % d'accuracy a forcément une sensibilité supérieure à 0,9.	VRAI FAUX
c	Un nœud d'un arbre de décision qui ne contient plus que des exemples positifs demande encore 1 bit d'information.	VRAI FAUX
d	Un attribut qui prend une valeur différente pour chaque exemple d'entraînement serait choisi par le critère du gain d'information, mais l'arbre obtenu ne généralise pas.	VRAI FAUX
e	La construction gloutonne de l'arbre par gain d'information garantit l'arbre le plus petit compatible avec les exemples.	VRAI FAUX
f	Le jeu de validation sert à décider quand arrêter l'apprentissage ; la performance finale se mesure sur un jeu de test distinct.	VRAI FAUX
g	Le clustering hiérarchique ascendant exige de fixer le nombre de clusters avant de démarrer.	VRAI FAUX
h	Un réseau multicouche dont tous les neurones ont une activation linéaire n'est pas plus puissant qu'un réseau à une seule couche.	VRAI FAUX
i	La dérivée de la sigmoïde logistique $f(s) = 1/(1+e^{-s})$ ne dépasse jamais 0,25.	VRAI FAUX
j	Une AUC de 0,3 indique un classement moins bon qu'un tirage au hasard.	VRAI FAUX

Exercice 2 (9 points)

Type : série 1 ex. 2 ; quiz 06.2 et 06.3 ; ZH 2023 Q2

Le réseau ci-dessous a deux entrées, deux neurones cachés A et B et un neurone de sortie. Les trois neurones utilisent la sigmoïde $f(s) = 1/(1+e^{-s})$. Chaque neurone reçoit aussi une entrée de biais constante égale à 1. On présente l'entrée $x = (x_1; x_2) = (2; -1)$ avec la sortie désirée $d = 0{,}2$. Taux d'apprentissage $\alpha = 0{,}5$. Convention imposée : $\varepsilon = d - y$, $E = \frac{1}{2}\varepsilon^2$, $w \leftarrow w - \alpha\, \partial E/\partial w$.



Neurone	biais	x_1	x_2
A	$w_{A0} = 0{,}2$	$w_{A1} = 0{,}4$	$w_{A2} = 0{,}5$
B	$w_{B0} = -0{,}3$	$w_{B1} = 0{,}1$	$w_{B2} = 0{,}3$
	biais	h_A	h_B
S	$v_0 = 0{,}1$	$v_A = 0{,}7$	$v_B = -0{,}5$

a) Passe avant : calculer s_A, h_A, s_B, h_B et la sortie y. (2 pt)
b) Calculer $\partial E/\partial v_A$, puis la nouvelle valeur de v_A. (2 pt)
c) Calculer la nouvelle valeur de w_{A1}, le poids qui relie x_1 au neurone A. (4 pt)
d) Quelle valeur de v_A faut-il utiliser en c), l'ancienne ou la nouvelle ? Le sens de variation de w_{A1} est-il cohérent avec $y > d$? (1 pt)

Exercice 3 (6 points)

Type : série 1 ex. 3

a) Recopier et compléter le tableau, puis esquisser les trois fonctions sur $[-3; 3]$ en indiquant les asymptotes et les pentes. (3 pt)

	$f(-2)$	$f(0)$	$f(2)$	$f'(0)$	$f'(2)$
sigmoïde $1/(1+e^{-s})$					
$\tanh(s)$					
ReLU $\max(0, s)$					

b) Une erreur doit remonter à travers quatre couches de neurones sigmoïdes pour atteindre la première couche. En ne gardant que le produit des dérivées des activations (poids ignorés), majorer ce facteur, puis le calculer si chaque neurone travaille à $s = 2$. Expliquer le phénomène de disparition du gradient (vanishing gradient) et dire quelles activations y sont les plus exposées. (3 pt)

Exercice 4 (9 points)

Type : série 2 ex. 3 ; ZH 2019 Q2, ZH 2022 Q5

Un module embarqué prédit si une pompe tombera en panne dans le mois (O : oui, N : non) à partir de trois attributs : vibration (F faible, H forte), température (B basse, M moyenne, H haute), âge (< 5 ans ou ≥ 5 ans). Douze exemples :

Exemple	1	2	3	4	5	6	7	8	9	10	11	12
Vibration	F	F	F	H	H	H	F	F	H	H	F	H
Température	B	B	B	B	M	M	M	M	H	H	H	H
Âge	≥ 5	≥ 5	< 5	< 5	< 5	< 5	≥ 5	< 5	≥ 5	≥ 5	≥ 5	< 5
Panne	N	N	N	N	O	O	N	N	O	O	O	N

Aide : $\text{Gain}(A) = I\left(\frac{p}{p+n}, \frac{n}{p+n}\right) - \sum_k \frac{p_k+n_k}{p+n} I\left(\frac{p_k}{p_k+n_k}, \frac{n_k}{p_k+n_k}\right)$, avec $I(a,b) = -a\log_2 a - b\log_2 b$.

a) Quelle quantité d'information faut-il à la racine ? (1 pt)
b) Calculer le gain d'information de chacun des trois attributs. Lequel tester à la racine ? (4 pt)
c) Pour chaque branche qui n'est pas homogène, choisir l'attribut à tester ensuite (gain à l'appui). (2 pt)
d) Dessiner l'arbre final et vérifier qu'il classe correctement les douze exemples. (2 pt)

Exercice 5 (9 points)

Type : série 2 ex. 1 ; ENT 2021 ex. 2 ; quiz 03.6

Un capteur acoustique fixé sur une canalisation mesure un niveau p sur 5 000 segments, dont 800 présentent une fuite. Un segment est déclaré « fuite » si $p \geq p_{\text{lim}}$. Le tableau donne, pour chaque seuil, le nombre de segments dont le niveau atteint ou dépasse ce seuil.

p_{lim}	10	20	30	40	50	60
Segments avec fuite, $p \geq p_{\text{lim}}$	800	760	640	400	120	0
Segments sans fuite, $p \geq p_{\text{lim}}$	4 200	1 890	630	210	42	0

Classe positive : fuite.

a) Pour $p_{\text{lim}} = 30$: donner TP, FN, FP, TN, puis la sensibilité, la spécificité, la précision, l'accuracy et le score F_1. (4 pt)
b) Calculer le point (FPR ; TPR) de chaque seuil et tracer la courbe ROC. (2 pt)
c) Estimer l'AUC par la méthode des trapèzes et l'interpréter. (2 pt)
d) Un détecteur répond toujours « pas de fuite ». Donner son accuracy et sa sensibilité. Que conclure sur l'accuracy obtenue en a) ? (1 pt)

Exercice 6 (7 points)

Type : série 2 ex. 2 ; quiz 04.3 et 04.4

Six capteurs A à F donnent les températures moyennes suivantes (°C) : A 20,0 ; B 21,5 ; C 25,5 ; D 27,5 ; E 30,5 ; F 34,0. La distance entre deux capteurs est la valeur absolue de la différence. On applique le clustering hiérarchique ascendant.

a) Avec le critère du minimum (single linkage), donner l'ordre des fusions et leur hauteur, puis dessiner le dendrogramme. (3 pt)
b) Avec une distance limite de 2,5, combien de clusters obtient-on ? Lesquels ? (1 pt)
c) Refaire l'ordre des fusions avec le critère du maximum (complete linkage). (2 pt)
d) Les deux critères donnent-ils la même partition en deux clusters ? (1 pt)

EMBAI, midterm blanc 2

50 points, 20 requis pour la signature. Calcul exigé dans les exercices 2 à 6 : un résultat sans calcul ne rapporte rien. Arrondir à 4 décimales.

Exercice 1 (10 points)

Entourer VRAI ou FAUX. Bonne réponse +1, mauvaise réponse −1, sans réponse 0 ; un total négatif est ramené à 0. Aucune justification n'est lue.

Type : bloc VRAI/FAUX des séries d'entraînement 2026 et des annales

a	Si une variable s'exprime en dizaines de kilogrammes et une autre en centièmes d'unité de pH, la distance euclidienne brute est dominée par la première.	VRAI FAUX
b	Deux exécutions de k-means sur les mêmes données peuvent donner des clusters différents si les centres initiaux diffèrent.	VRAI FAUX
c	Le kNN concentre son calcul dans la phase d'apprentissage ; classer un nouveau point est ensuite presque gratuit.	VRAI FAUX
d	La PCA peut décrire une relation non linéaire entre deux variables.	VRAI FAUX
e	La première composante principale est le vecteur propre de la matrice de covariance associé à la plus grande valeur propre.	VRAI FAUX
f	Une sensibilité égale à 1 garantit qu'il n'y a aucun faux positif.	VRAI FAUX
g	On entraîne en général les grands réseaux de neurones directement sur l'appareil embarqué.	VRAI FAUX
h	En Edge AI, traiter les données sur l'appareil réduit le temps de réponse.	VRAI FAUX
i	La dérivée de ReLU vaut 0 pour $s < 0$ et 1 pour $s > 0$.	VRAI FAUX
j	Modifier les poids dans la direction du gradient de l'erreur, $+\nabla E$, fait diminuer l'erreur.	VRAI FAUX

Exercice 2 (8 points)

Type : quiz 06.1, 06.2 et 06.3 ; série 1 ex. 2 ; ZH 2023 Q2, EX 2023 Q4

Un neurone calcule $s = w_0 + w_1x_1 + w_2x_2 + w_3x_3$ et $y = \tanh(s)$. Poids actuels : $w_0 = 0{,}1$; $w_1 = 0{,}4$; $w_2 = -0{,}2$; $w_3 = 0{,}3$. Entrée $(x_1; x_2; x_3) = (0{,}5; -1; 2)$, sortie désirée $d = 0{,}3$, taux $\alpha = 0{,}2$. Convention imposée : $\varepsilon = d - y$, $E = \varepsilon^2$, $w \leftarrow w - \alpha\, \partial E/\partial w$.

a) Calculer la sortie y. (1 pt)
b) Calculer $\partial y/\partial w_2$. (2 pt)
c) Calculer la nouvelle valeur de w_3. (3 pt)
d) Pourquoi ne prend-on pas simplement $E = \varepsilon$, ou $E = |\varepsilon|$? (2 pt)

Exercice 3 (8 points)

Type : série 1 ex. 4 ; EX 2022 Q2 ; quiz 04.2

On regroupe en $K = 2$ clusters, par k-means et distance euclidienne, les huit points $P_1(3;1)$, $P_2(3;0)$, $P_3(3;4)$, $P_4(4;7)$, $P_5(7;8)$, $P_6(9;8)$, $P_7(9;9)$, $P_8(9;7)$. Centres initiaux : $c_1 = (3;5)$, $c_2 = (9;3)$.

a) Affecter chaque point (tableau des distances) et donner les centres après la première itération. (3 pt)
b) Faire la deuxième itération. (2 pt)
c) Faire la troisième itération : l'algorithme s'arrête-t-il ? Dans quelle direction c_2 s'est-il déplacé à chaque itération ? (2 pt)
d) Avec $N = 10\,000$ points de dimension $d = 8$, $K = 2$ et $J = 20$ itérations, donner l'ordre de grandeur du coût de k-means. (1 pt)

Exercice 4 (8 points)

Type : cours 3 (kNN) et 4 (distances) ; quiz 03.1 et 04.1

Un moteur est décrit par son courant x_1 (A) et sa vibration x_2 (mm/s). Sur l'historique, les écarts-types valent $\sigma_1 = 20$ A et $\sigma_2 = 0{,}5$ mm/s. Six exemples étiquetés (D : défaut, N : normal) et un nouveau moteur $q = (60; 2{,}0)$:

	D1	D2	D3	N1	N2	N3
x_1 (A)	58	63	55	68	48	75
x_2 (mm/s)	3,4	3,1	3,6	2,1	1,8	2,2

a) Calculer la distance euclidienne de q à chaque exemple et classer q par 3-NN. (3 pt)
b) Recommencer avec la distance de Mahalanobis à covariance diagonale. Avec 5-NN, quelle proportion de voisins vote pour la classe retenue ? Quelle distance choisir ici, et pourquoi ? (3 pt)
c) La base contient $N = 4\,000$ exemples de dimension $d = 12$. Combien de multiplications faut-il pour obtenir les N distances euclidiennes au carré d'un nouveau point ? La racine carrée est-elle nécessaire ? Quelle est la complexité d'un classement ? (2 pt)

Exercice 5 (8 points)

Type : cours 4 (PCA) et TP 3

Quatre observations de deux variables : $(-1;1)$, $(3;1)$, $(5;1)$, $(5;5)$.

a) Centrer les données et calculer la matrice de covariance $\Sigma = \frac{1}{N}\mathbf{X}_{\text{st}}^{\top}\mathbf{X}_{\text{st}}$ ($\mathbf{X}_{\text{st}}$: données centrées, une observation par ligne). (3 pt)
b) Calculer les valeurs propres de Σ et le vecteur propre unitaire $\mathbf{u}_1$ de la plus grande. (2 pt)
c) Quelle part de la variance la première composante décrit-elle ? (1 pt)
d) Donner la coordonnée de chaque observation sur la première composante. (1 pt)
e) Citer une limite de la PCA. (1 pt)

Exercice 6 (8 points)

Type : cours 5, cas d'usage détection de chute ; cours 2 (énergie)

Un bracelet détecte les chutes à partir d'un accéléromètre trois axes échantillonné à 62,5 Hz, découpé en fenêtres de 2 s.

a) Un échantillon vaut $(a_x; a_y; a_z) = (12; -9; 20)$ m/s². Calculer la norme de l'accélération et la G-force. (2 pt)
b) Sur une fenêtre réduite à cinq valeurs, $X = [10; 9; 10; 15; 11]$, normaliser la valeur 15 comme dans le cours (écart-type calculé en divisant par N). (2 pt)
c) Combien d'échantillons contient une fenêtre, par axe et pour les trois axes ? Les 3 600 fenêtres sont réparties à 70 : 15 : 15 ; donner la taille de chaque jeu. (1 pt)
d) Détection d'anomalie, version réduite à deux dimensions : deux clusters de centres $c_1 = (0;0)$, $c_2 = (4;3)$ et de rayons $r_1 = 1$, $r_2 = 1{,}5$; score $d(x) = \min_k(\|x - c_k\| - r_k)$, anomalie si $d(x) > 0{,}5$. Classer $x_a = (0{,}6; -0{,}8)$ et $x_b = (2; 4{,}5)$. (2 pt)
e) Donner deux raisons chiffrées de passer le réseau de float32 à int8, et ce qu'il faut vérifier ensuite. (1 pt)

Corrigé du midterm blanc 1

Exercice 1 (6 V, 4 F)

a. **V.** $N \log N$ croît moins vite que N^2 (cours 1, complexité).
b. **F.** Classes déséquilibrées : un test qui répond toujours « négatif » peut avoir 92 % d'accuracy et une sensibilité nulle (cours 3, p. 41).
c. **F.** Nœud homogène : $I(1,0) = 0$ bit.
d. **V.** Gain maximal sur l'apprentissage, aucune généralisation : l'arbre mémorise (cours 3, p. 26).
e. **F.** Glouton : optimum local à chaque nœud ; trouver le plus petit arbre est en général intraitable (cours 3, p. 13 et 14).
f. **V.** Cours 3, p. 31 et 32 ; TP NN4a, early stopping.
g. **F.** Il ne demande pas K ; on coupe le dendrogramme ensuite (cours 4, p. 28).
h. **V.** Sans non-linéarité, la capacité se réduit à celle d'une couche (TP NN4a).
i. **V.** $f' = y(1-y)$, maximum 0,25 en $s = 0$.
j. **V.** AUC < 0,5 : pire que le hasard (cours 3, p. 50).

Exercice 2

a) $s_A = 0{,}2 + 0{,}4 \cdot 2 + 0{,}5 \cdot (-1) = 0{,}5$, $h_A = 0{,}6225$. $s_B = -0{,}3 + 0{,}2 - 0{,}3 = -0{,}4$, $h_B = 0{,}4013$. $s_S = 0{,}1 + 0{,}7 \cdot 0{,}6225 - 0{,}5 \cdot 0{,}4013 = 0{,}3351$, $y = 0{,}5830$.

b) $\varepsilon = 0{,}2 - 0{,}5830 = -0{,}3830$; $f'(s_S) = y(1-y) = 0{,}2431$. Gradient local $\delta_S = \varepsilon f'(s_S) = -0{,}09311$. $\partial E/\partial v_A = \varepsilon \cdot (-1) \cdot f'(s_S) \cdot h_A = -\delta_S h_A = 0{,}05796$. $v'_A = 0{,}7 - 0{,}5 \cdot 0{,}05796 = \mathbf{0{,}6710}$.

c) $\delta_A = f'(s_A)\,\delta_S\,v_A = 0{,}2350 \cdot (-0{,}09311) \cdot 0{,}7 = -0{,}01532$. $w'_{A1} = w_{A1} + \alpha\,\delta_A\,x_1 = 0{,}4 + 0{,}5 \cdot (-0{,}01532) \cdot 2 = \mathbf{0{,}3847}$.

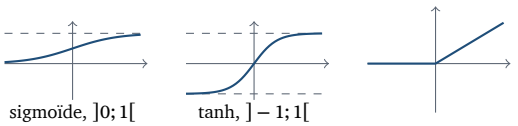
d) L'ancienne : les gradients se calculent tous au point de la passe avant. Avec $v'_A = 0{,}6710$, on obtiendrait 0,3853. Signe : $y > d$, il faut baisser y ; $v_A > 0$ et $x_1 > 0$, donc w_{A1} doit baisser : cohérent.

Pièges. Avec $E = \varepsilon^2$ (corrigés d'annales), les corrections doublent : $v'_A = 0{,}6420$, $w'_{A1} = 0{,}3694$. $\varepsilon = y - d$ sans changer la règle inverse le sens. B ne joue pas sur w_{A1}.

Exercice 3

a)

	$f(-2)$	$f(0)$	$f(2)$	$f'(0)$	$f'(2)$
sigmoïde	0,119	0,5	0,881	0,25	0,105
tanh	−0,964	0	0,964	1	0,071
ReLU	0	0	2	non définie	1



b) Le gradient d'une couche est un produit de dérivées des couches situées après elle (règle de chaîne). Pour la sigmoïde, $f' \le 0{,}25$, donc le facteur est au plus $0{,}25^4 = 0{,}0039$; à $s = 2$, $0{,}105^4 \approx 1{,}2 \cdot 10^{-4}$. Les premières couches ne reçoivent presque plus de correction et cessent d'apprendre. Sigmoïde et tanh sont les plus exposées : elles saturent ($f' \approx 0$ pour $|s|$ grand). Le TP NN4a parle de paralysie du réseau (activation sigmoïde et très grands poids). ReLU l'est peu : $f' = 1$ pour $s > 0$, mais $f' = 0$ pour $s < 0$.

Exercice 4

a) 5 O, 7 N : $I(\frac{5}{12}, \frac{7}{12}) = \mathbf{0{,}9799}$ bit.

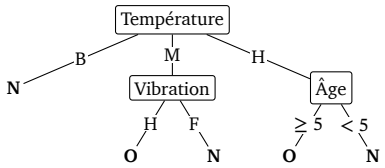
b) Comptes $(p_k; n_k)$ par valeur, $I(\frac{2}{3}, \frac{1}{3}) = 0{,}9183$, $I(\frac{1}{6}, \frac{5}{6}) = 0{,}6500$, $I(\frac{3}{4}, \frac{1}{4}) = 0{,}8113$.

Attribut	branches	reste	gain
Vibration	H (4 ; 2), F (1 ; 5)	0,7842	0,1957
Température	B (0 ; 4), M (2 ; 2), H (3 ; 1)	0,6038	**0,3761**
Âge	≥ 5 (3 ; 3), < 5 (2 ; 4)	0,9591	0,0207

Température : reste $= \frac{1}{3}\cdot 0 + \frac{1}{3}\cdot 1 + \frac{1}{3}\cdot 0{,}8113$. Racine : **température**. Branche B : feuille N.

c) Branche M (exemples 5 à 8, 2 O, 2 N) : vibration sépare parfaitement, gain 1 (âge : 0,3113). Branche H (exemples 9 à 12, 3 O, 1 N) : âge sépare parfaitement, gain 0,8113 (vibration : 0,1226).

d) Arbre final :



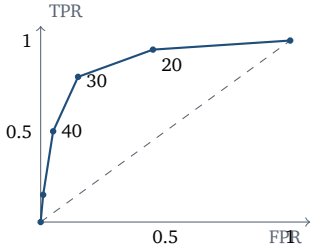
Les douze exemples tombent dans la bonne feuille. Piège : oublier le poids $\frac{p_k+n_k}{p+n}$ des branches.

Exercice 5

a) $P = 800$, $N = 4\,200$. $TP = 640$, $FN = 160$, $FP = 630$, $TN = 3\,570$. Sensibilité 640/800 = 0,80 ; spécificité 3 570/4 200 = 0,85 ; précision 640/1 270 = 0,5039 ; accuracy 4 210/5 000 = 0,842 ; $F_1 = 2 \cdot 0{,}5039 \cdot 0{,}8/1{,}3039 = 0{,}6184$.

b) FPR $= FP/4\,200$, TPR $= TP/800$:

p_{lim}	FPR	TPR
10	1	1
20	0,45	0,95
30	0,15	0,80
40	0,05	0,50
50	0,01	0,15
60	0	0

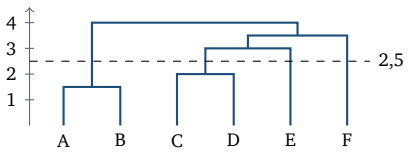


c) Trapèzes $\frac{(\text{FPR}_{i+1} - \text{FPR}_i)(\text{TPR}_i + \text{TPR}_{i+1})}{2}$: 0,00075 + 0,013 + 0,065 + 0,2625 + 0,53625 = **0,8775**. Nettement au-dessus de 0,5 (attribut sans rapport) et en dessous de 1 (attribut idéal) : p est informatif.

d) Accuracy 4 200/5 000 = 0,84, sensibilité 0. Le détecteur de a) ne fait que 0,842 : classes déséquilibrées, l'accuracy seule ne juge pas ; regarder sensibilité, précision, F_1.

Exercice 6

a) Écarts consécutifs : AB 1,5 ; BC 4,0 ; CD 2,0 ; DE 3,0 ; EF 3,5. En single linkage, deux clusters voisins sont à l'écart entre leurs bords : AB à 1,5 ; CD à 2,0 ; (CD)E à 3,0 ; (CDE)F à 3,5 ; tout à 4,0.



b) La coupe à 2,5 traverse quatre traits : **4 clusters**, $\{A, B\}$, $\{C, D\}$, $\{E\}$, $\{F\}$.

c) Complete (points les plus éloignés) : AB à 1,5 ; CD à 2,0 ; (CD)E vaut 5,0, EF 3,5 : **EF à 3,5** ; (AB)(CD) 7,5 contre (CD)(EF) 8,5 : **ABCD à 7,5** ; tout à 14,0.

d) Non : single donne $\{A, B\}$, $\{C, D, E, F\}$ (effet de chaîne), complete $\{A, B, C, D\}$, $\{E, F\}$ (quiz 04.4).

Corrigé du midterm blanc 2

Exercice 1 (5 V, 5 F)

a. **V**. Exemple masse et pH du cours 4 (p. 7) : il faut Mahalanobis ou une mise à l'échelle.
b. **V**. Sensibilité à l'initialisation, optimum local (cours 4, p. 8).
c. **F**. Pas d'apprentissage : tout le coût, $O(dN)$, est payé à chaque classement (cours 3, p. 6).
d. **F**. Elle ne traite que les relations linéaires (cours 4, p. 48).
e. **V**. Cours 4, p. 45 et 46.
f. **F**. Sensibilité = 1 signifie $FN = 0$; rien sur les FP (tout déclarer positif donne 1).
g. **F**. « We usually do not train in embedded devices » (cours 2, défi 1) ; on peut au plus réajuster un modèle déjà entraîné.
h. **V**. Traitement local, latence réduite (cours 1, EdgeAI).
i. **V**. Non dérivable en 0 seulement.
j. **F**. Il faut aller selon $-\nabla E$.

Exercice 2

a) $s = 0{,}1 + 0{,}4 \cdot 0{,}5 + (-0{,}2)(-1) + 0{,}3 \cdot 2 = 1{,}1$; $y = \tanh(1{,}1) =$ **0,8005**.

b) $\partial y/\partial w_2 = f'(s)\, x_2 = (1 - y^2)\, x_2 = 0{,}3592 \cdot (-1) =$ **−0,3592**.

c) $\varepsilon = 0{,}3 - 0{,}8005 = -0{,}5005$. $\frac{\partial E}{\partial w_3} = 2\varepsilon \cdot (-1) \cdot f'(s) \cdot x_3 = 2 \cdot 0{,}5005 \cdot 0{,}3592 \cdot 2 = 0{,}7191$. $w_3' = 0{,}3 - 0{,}2 \cdot 0{,}7191 =$ **0,1562**. Contrôle : $y > d$ et $x_3 > 0$, le poids baisse. Avec $E = \frac{1}{2}\varepsilon^2$: $w_3' = 0{,}2281$.

d) $E = \varepsilon$: minimiser pousse ε vers $-\infty$ (sortie aussi grande que possible), et sur plusieurs exemples les erreurs de signes opposés se compensent. $E = |\varepsilon|$: non dérivable en $\varepsilon = 0$, et sa dérivée vaut ± 1 quelle que soit la taille de l'erreur. ε^2 est dérivable partout, toujours positive, et son gradient est proportionnel à l'erreur.

Piège. $f' = 1 - y^2$ se calcule avec y, pas avec s.

Exercice 3

a) d^2 à $c_1 = (3;5)$ et $c_2 = (9;3)$: P_1 16 et 40 ; P_2 25 et 45 ; P_3 1 et 37 ; P_4 5 et 41 ; P_5 **25 et 29** ; P_6 45 et 25 ; P_7 52 et 36 ; P_8 40 et 16. Groupe 1 : P_1 à P_5 ; groupe 2 : P_6, P_7, P_8. $c_1 = (20/5; 20/5) =$ (**4**; **4**), $c_2 =$ (**9**; **8**).

b) d^2 à (4; 4) et (9; 8) : P_4 9 et 26 (reste en 1) ; P_5 25 et 4 : P_5 **passe en 2**. Groupe 1 : P_1 à P_4, $c_1 = (13/4; 12/4) =$ (**3,25**; **3**). Groupe 2 : P_5 à P_8, $c_2 = (34/4; 32/4) =$ (**8,5**; **8**).

c) Avec (3,25; 3) et (8,5; 8) : P_4 16,56 et 21,25 ; P_5 39,06 et 2,25 ; aucune affectation ne change, les centres ne bougent plus : arrêt. c_2 : de (9; 3) à (9; 8), vers le haut de 5 ; puis de (9; 8) à (8,5; 8), vers la gauche de 0,5. Méthode du quiz 04.2 : réaffecter d'abord, puis prendre la moyenne ; ne pas deviner à l'œil.

d) $O(NKJd)$: $10\,000 \cdot 2 \cdot 20 \cdot 8 = 3{,}2 \cdot 10^6$ opérations élémentaires, soit $NKJ = 400\,000$ calculs de distance.

Exercice 4

a) $d^2 = \Delta x_1^2 + \Delta x_2^2$: D1 5,96 ; D2 10,21 ; D3 27,56 ; N1 64,01 ; N2 144,04 ; N3 225,04 (distances 2,44 ; 3,20 ; 5,25 ; 8,00 ; 12,00 ; 15,00). 3 plus proches : D1, D2, D3 : **défaut**. Le courant écrase la vibration.

b) $d_M^2 = (\Delta x_1/20)^2 + (\Delta x_2/0{,}5)^2$: D1 7,85 ; D2 4,8625 ; D3 10,3025 ; N1 0,20 ; N2 0,52 ; N3 0,7225. 3-NN : N1, N2, N3 : **normal**. 5-NN : N1, N2, N3, D2, D1, soit 3 voix sur 5, 60 % pour « normal ». Mahalanobis : les écarts-types diffèrent d'un facteur 40, une différence de 1,4 mm/s compte bien plus qu'une différence de 2 A (quiz 04.1).

c) $Nd = 48\,000$ multiplications (autant de soustractions, $N(d-1) = 44\,000$ additions). La racine est inutile : elle ne change pas l'ordre des distances. Coût $O(dN)$ à chaque classement, sans phase d'apprentissage : lourd pour un système embarqué, d'où le calcul parallèle sur plusieurs nœuds (cours 3, p. 6).

Exercice 5

a) Moyenne (3; 2). Données centrées : (−4; −1), (0; −1), (2; −1), (2; 3). $\sum x^2 = 24$, $\sum y^2 = 12$, $\sum xy = 8$, donc

$$\Sigma = \tfrac{1}{4}\begin{pmatrix} 24 & 8 \\ 8 & 12 \end{pmatrix} = \begin{pmatrix} 6 & 2 \\ 2 & 3 \end{pmatrix}.$$

b) $\lambda^2 - 9\lambda + 14 = 0$: $\lambda_1 =$ **7**, $\lambda_2 =$ **2**. $(6-7)u_x + 2u_y = 0$ donne $u_y = u_x/2$, $\mathbf{u}_1 = (2;1)/\sqrt{5} = (0{,}8944; 0{,}4472)$.

c) $7/(7+2) =$ **77,8** %.

d) $\mathbf{u}_1^\top \mathbf{x}_{(st)}$: $-9/\sqrt{5} = -4{,}025$; $-1/\sqrt{5} = -0{,}447$; $3/\sqrt{5} = 1{,}342$; $7/\sqrt{5} = 3{,}130$. Contrôle : somme nulle, variance $140/20 = 7 = \lambda_1$.

e) Relations linéaires seulement ; nouvelles variables difficiles à interpréter (cours 4, p. 48 et 50).

Pièges. Ne pas oublier de centrer ; diviser par $N = 4$ comme la slide ; le signe de $\mathbf{u}_1$ est arbitraire.

Exercice 6

a) $|a| = \sqrt{144 + 81 + 400} = \sqrt{625} =$ **25** m/s² ; G-force 25/9,8 = **2,551**.

b) Moyenne 11 ; écarts $-1, -2, -1, 4, 0$; variance $22/5 = 4{,}4$; std = 2,0976. $x_n = (15 - 11)/2{,}0976 =$ **1,907**. Avec la division par $N - 1$, on trouverait 1,706 : suivre la formule de la slide.

c) $62{,}5 \times 2 = 125$ échantillons par axe, 375 pour trois axes. $3\,600 \times 0{,}70 = 2\,520$; $0{,}15 \times 3\,600 = 540$ en validation et 540 en test.

d) x_a : $\|x_a - c_1\| = 1$, score $1 - 1 = 0$ (c_2 donne 3,599) : $d(x_a) = 0$, **normal**. x_b : $\|x_b - c_1\| - 1 = 3{,}924$; $\|x_b - c_2\| = \sqrt{4 + 2{,}25} = 2{,}5$, score 1,0 ; $d(x_b) = 1{,}0 > 0{,}5$: **anomalie**. Prendre le minimum sur les clusters, pas la distance au cluster le plus proche sans rayon.

e) Mémoire des poids divisée par 4 (4 octets contre 1). Énergie : une multiplication 8 bits coûte 0,2 pJ contre 3,7 pJ en flottant 32 bits (cours 2), environ 18 fois moins. Ensuite, comparer l'accuracy et la matrice de confusion du modèle int8 à celles du modèle float32 sur le même jeu de test : le cours 5 montre une légère baisse, sans chute manquée.