EMBAI, synthèse midterm (BMEVIMIMA22). 2026-10-29, 18h00 à 20h00. 50 points en 6 exercices, signature à 20. VRAI/FAUX : +1 juste, −1 faux, 0 en blanc, total ramené à 0. Espérance d'une réponse $= 2p - 1$: ne répondre que si l'on est nettement sûr. Écrire en première ligne les conventions (fonction d'erreur, classe positive). Calcul exigé : le résultat seul ne rapporte rien. Calculatrice avec e^x et ln ; $\log_2 x = \ln x / \ln 2$.

1. VRAI/FAUX qui reviennent

Cours 1 et 2

F $O(N^2)$ est moins coûteux que $O(\log_2 N)$ pour N grand.
V $O(\log_3 N)$ et $O(\log_2 N)$ sont la même classe (facteur $\log_2 3 \approx 1{,}585$) ; par tiers, il faut pourtant moins de pesées.
F Le cerveau suit l'ordinateur car son temps de cycle est plus court. Un neurone met environ 1 ms ; l'avantage tient au parallélisme et aux 20 W.
F En Edge AI, les calculs sont faits dans le cloud (inférence sur l'appareil).
V Il faut des solutions intelligentes : l'espace d'états est trop grand pour la force brute.
F Un agent rationnel prend toujours la décision qui se révèle a posteriori la meilleure (il maximise l'utilité espérée).
V Un agent rationnel peut prendre une décision qui conduit ensuite à une perte.
F Rationnel signifie choisir la solution au temps d'exécution le plus court.
V Quantification : réduire la précision des poids ; élagage : supprimer poids ou neurones.

Cloud ou local : aucun des deux ne résout la limite d'énergie locale ; local améliore le temps de réaction ; cloud aide la mémoire. CPU orienté latence, GPU orienté débit.

Information et arbres

V Quatre directions équiprobables : 2 bits.
F Deux directions : 2 bits (au plus 1).
V Deux issues sans information préalable : 1 bit.
F Carte du dessus est un carreau : 1 bit ($I(\frac{1}{4}, \frac{3}{4}) = 0{,}811$).
V Quatre couleurs équiprobables demandent plus d'information qu'homme ou femme (2 contre au plus 1).
F Trois couleurs équiprobables : exactement 3 bits ($\log_2 3 = 1{,}585$).
F Nœud où n'arrive qu'une classe : 1 bit (0 bit).
F Nœud à effectifs égaux des deux classes : besoin nul (1 bit, le maximum).
F L'arbre trivial généralise bien (il mémorise ; la forme « ne généralise pas » est V).
V Un attribut à valeur propre à chaque exemple est sans valeur comme test (gain maximal, mais mémorisation).
F Un tel attribut (numéro de série) est le meilleur test à la racine.
V Le gain ne dépend pas seulement du besoin avant et après le test (aussi du poids $(p_k + n_k)/(p + n)$).
F 10 attributs binaires tous testés sur un chemin : feuille certainement homogène (bruit d'étiquette).
V La construction de l'arbre est gloutonne. **F** : c'est une recherche en largeur. **F** : elle trouve toujours le plus petit arbre.
V Un arbre peut représenter toute fonction logique de ses attributs (taille parfois exponentielle).

Métriques, ROC, validation

F L'accuracy mesurée sur des jeux différents, grands et de même taille désigne la meilleure méthode (proportions de classes).
F 92 % d'accuracy est forcément mieux que 80 % (exemple B du cours 3, inutile).
V Sensibilité 1 : tous les positifs détectés ($FN = 0$) ; rien sur les FP.
F L'AUC vaut typiquement 1 pour un tirage au hasard (0,5). **F** : AUC d'un attribut non pertinent = 1.
V AUC 0,83 contre 0,75 : le second attribut est meilleur.
V AUC 0,3 : pire que le hasard.
F La sensibilité est toujours inférieure à la spécificité (cours : 0,8 et 0,55).
V Tout déclarer positif : TPR = 1, TNR = 0 (item ZH 2021 mal rédigé : blanc possible).
V FPR = 1 − spécificité.
F Le jeu de validation mesure la performance finale (c'est le test).
F Contre le surapprentissage, on surveille l'erreur d'apprentissage (validation).
V L'erreur d'apprentissage peut encore baisser en phase de surapprentissage. **F** : elle ne diminue plus.
V Les outils moins complexes sont moins enclins au surapprentissage (et inversement).
F 8 exemples, MLP à 5 couches de 10 : judicieux (centaines de poids).
F Ajouter des neurones cachés fait toujours baisser l'erreur de test.

Clustering

V Écarts-types très différents : Mahalanobis préférable à l'euclidienne.
F K-means ne dépend pas des centres initiaux.
V Coût de k-means $O(NKJd)$.
F Le hiérarchique ascendant exige le nombre de clusters à l'avance.
F Single et complete linkage donnent toujours les mêmes fusions.
V DBSCAN isole le bruit sans fixer le nombre de clusters.
F La PCA capte les relations non linéaires.

Réseaux de neurones

F La pente de ReLU est toujours inférieure à 1 (ou à 0,5) : elle vaut 0 ou 1.
F La dérivée de ReLU vaut +1 ou −1 (0 ou +1).
V La pente de la sigmoïde est toujours inférieure à 1 ($\leq 0{,}25$).
V En rétropropagation, les dérivées des sigmoïdes se multiplient entre elles.
V BP calcule la sensibilité de l'erreur à chaque poids par la règle de chaîne.
F Aller dans la direction du gradient fait baisser l'erreur (opposée : $-\nabla E$).
F Aller selon $-\nabla E$ fait d'abord monter l'erreur.
F Aller perpendiculairement au gradient fait certainement monter l'erreur.
V 2000 neurones vers 50 : de l'ordre de 100 000 poids.
F MLP à trois couches de 20, entièrement connecté : au plus 60 poids (400 par liaison).
V Perceptron simple sans erreur seulement si linéairement séparable.
F Le 13e problème de Hilbert donne le nombre de neurones nécessaire.
V Sans activation non linéaire, un multicouche n'est pas plus puissant qu'une couche.
F Cas d'usage chute : int8 plus juste que float32 (552 contre 555 sur 561).

2. Un pas d'apprentissage (série 1 ex. 2, quiz 06.3)

$s = \sum_k w_k x_k$ avec $x_0 = 1$ pour le biais ; $y = f(s)$; $\varepsilon = d - y$.

$$\frac{\partial E}{\partial w_k} = \frac{\partial E}{\partial \varepsilon}\frac{\partial \varepsilon}{\partial y}\frac{\partial y}{\partial s}\frac{\partial s}{\partial w_k} = c\,\varepsilon \cdot (-1) \cdot f'(s) \cdot x_k$$

$c = 1$ si $E = \frac{1}{2}\varepsilon^2$ (TP), $c = 2$ si $E = \varepsilon^2$ (corrigés des annales).

$$w_k \leftarrow w_k - \alpha \frac{\partial E}{\partial w_k} = w_k + \alpha\, c\, \varepsilon\, f'(s)\, x_k$$

Sortie : $\delta_{\text{out}} = c\,\varepsilon\, f'(s_{\text{out}})$. Caché j : $\delta_j = f'(s_j) \sum_k \delta_k w_{kj}$ (anciens poids). Mise à jour : $\Delta w = \alpha\, \delta \times$ entrée portée par ce poids (1 pour un biais, x_i, ou h_j pour un poids caché vers la sortie). Quiz 06.2 : $\frac{\partial y}{\partial w_k} = f'(s)\, x_k$. Perceptron à seuil (sortie ±1) : $w \leftarrow w + \alpha\, \varepsilon\, x$, $\varepsilon \in \{0, \pm 2\}$.

Méthode.

1. Écrire E et $\varepsilon = d - y$.
2. Passe avant, neurone par neurone : s, puis $f(s)$; 4 décimales.
3. f' : sigmoïde $y(1-y)$; tanh $1 - y^2$; ReLU 0 ou 1 ; s^2 donne $2s$; linéaire 1.
4. δ_{out}, puis δ_j des cachés avec les anciens poids de sortie.
5. $w_{\text{nouveau}} = w + \alpha\, \delta \times$ entrée. Contrôle : $y < d$, entrée et $f' > 0$: le poids monte.

Série 1 ex. 2 ($d = 0{,}9$, $\alpha = 0{,}1$, nouveau w_{01}). $s_1 = 0{,}6$, $h_1 = 0{,}6457$; $s_2 = 0{,}85$, $h_2 = 0{,}7006$; $s_{\text{out}} = -0{,}5063$, $y = 0{,}3761$; $\varepsilon = 0{,}5239$; $f'(s_{\text{out}}) = 0{,}2347$; $f'(s_1) = 0{,}2288$.

	$E=\varepsilon^2$	$E=\frac{1}{2}\varepsilon^2$
δ_{out}	0,2459	0,1229
$\delta_1=\delta_{\text{out}}\,w_1\,f'(s_1)$	0,01688	0,00844
nouveau w_{01}	**0,8017**	**0,8008**
nouveau w_1 (variante V5)	0,3159	0,3079

Hidden2 ne joue pas sur w_{01} ; $w_{11}=0$ et $x_1=5$ sont des distracteurs. **Annales.** ZH 2023, $y=s^2$, poids $(0{,}5;0{,}2;2{,}5)$, $x=(1;0{,}7;-0{,}2)$, $d=0{,}2$, $\alpha=0{,}1$: $s=0{,}14$, $y=0{,}0196$, $\varepsilon=0{,}1804$, $\partial E/\partial w_k=-4\varepsilon s x_k$; poids $(0{,}5101;0{,}2071;2{,}498)$. EX 2023, ReLU, poids $(1;-1;2)$, même échantillon : $s=-0{,}1$, $f'=0$, **aucun poids ne change**. PZH 2022, seuil, poids $(-0{,}4;0{,}2;0{,}5)$, $d=+1$: $s=-0{,}36$, $y=-1$, $\varepsilon=2$, poids $(-0{,}2;0{,}34;0{,}46)$. EX 2020-3, sans biais, $w=(-1;1)$, $x=(-1;3)$, $d=-1$, $y=+1$: $\varepsilon=-2$, $w=(-0{,}8;0{,}4)$.

Pièges. Facteur 2 oublié ou ajouté ; signe ($\varepsilon=y-d$ inverse la mise à jour) ; poids de sortie déjà mis à jour utilisé pour δ_j. Convention du cours 6 non vérifiée : donner celle de l'énoncé, sinon écrire celle choisie. Corrigé officiel ZH 2023 : écrit x_0 au lieu de x_1 dans w_1 (valeur 0,7 juste). Le corrigé EX 2023 insiste : comprendre la méthode du gradient, l'élément clé n'est pas toujours f'.

Quiz 06.1, $E=\varepsilon$ ou $|\varepsilon|$: avec ε, minimiser pousse vers $-\infty$ et les signes se compensent ; $|\varepsilon|$ n'est pas dérivable en 0 et sa dérivée garde l'amplitude ±1 ; ε^2 est dérivable, dérivée proportionnelle à l'erreur.

3. Arbre de décision et gain d'information

Formules (fournies dans l'énoncé de la série 2) :

$$I=-\sum_j P(j)\log_2 P(j),\quad I\Big(\tfrac{p}{p+n},\tfrac{n}{p+n}\Big)=-\tfrac{p}{p+n}\log_2\tfrac{p}{p+n}-\tfrac{n}{p+n}\log_2\tfrac{n}{p+n}$$

$$\text{Gain}(A)=I\Big(\tfrac{p}{p+n},\tfrac{n}{p+n}\Big)-\sum_k\tfrac{p_k+n_k}{p+n}\,I\Big(\tfrac{p_k}{p_k+n_k},\tfrac{n_k}{p_k+n_k}\Big)$$

1/2; 1/2	1	1/4; 3/4	0,811	0,8; 0,2	0,722
$4\times1/4$	2	1/3; 2/3	0,918	0,9; 0,1	0,469
1; 0	0	2/5; 3/5	0,971	1/6; 5/6	0,650

n issues équiprobables : $\log_2 n$ ($\log_2 3=1{,}585$). $0\log 0=0$. Calculer en ln ne change pas le classement des attributs.

Méthode.

1. Racine : compter p, n ; I_0.
2. Tableau des branches : exemples, $(p_k;n_k)$, I_k (pure : 0 ; équilibrée : 1).
3. Reste $=\sum_k\frac{p_k+n_k}{p+n}I_k$, **pondéré**.
4. Gain $=I_0-$ reste ; tester l'attribut de gain maximal (glouton).
5. Branche impure : ne garder que ses exemples, recommencer. Attribut constant sur la branche : gain nul.

Résultats. Série 2 ex. 3 (tennis, 5 V, 5 D) : surface H (3 ; 0), G (1 ; 3), C (1 ; 2), reste $0{,}3\cdot0+0{,}4\cdot0{,}811+0{,}3\cdot0{,}918=0{,}600$, **gain 0,40 bit** ; météo 0,151 ; taille 0,039 : racine surface, feuille H = Y. ZH 2019 (5000 ; 5000, cinq branches) : $1-0{,}4-0{,}1=0{,}5$. PZH 2019, quatre classes : $2-0{,}1\times2=1{,}8$. ZH 2020 : position, gain $\frac{2}{3}$; branche H : la paire de fous sépare, l'avantage matériel (constant) non. ZH 2022 : avantage matériel, $1-0{,}9387=0{,}061$. ENT 2019 : même branche impure ($\frac{1}{4},\frac{3}{4}$), poids 0,5 contre 0,05 : gains 0,594 et 0,959.

Pièges. Cours 3 p. 22 : « $2-4\times1=-2$ » est faux, reste $=4\times\frac{1}{4}\times1=1$, gain 1. Coquille de l'énoncé série 2 : $\frac{p}{p+n}$ écrit deux fois, le second terme porte sur n. Quiz 03.5 (raté) : pièce à 80 %, $I=0{,}722$ bit. n attributs binaires : 2^n instances, 2^{2^n} fonctions (10 : 1024 et 2^{1024}) ; valeurs $k_1,k_2,\ldots$: $k_1k_2\cdots$ instances.

4. Matrice de confusion, ROC, AUC

Réel \ prédit	P	N	
P	TP	FN (type II)	sensibilité $TP/(TP+FN)$
N	FP (type I)	TN	spécificité $TN/(TN+FP)$

précision $TP/(TP+FP)$; VPN $TN/(TN+FN)$; accuracy $(TP+TN)/\text{total}$

FPR $=1-$ spécificité $=FP/(FP+TN)$. $F_1=2PS/(P+S)$, avec P la précision et S la sensibilité. Entropie croisée : $-\frac{1}{N}\sum_i[y_i\log p(x_i)+(1-y_i)\log(1-p(x_i))]$.

Méthode (tableau de seuils).

1. Classe positive = ce qu'on détecte (défectueux, malade) ; l'écrire.
2. Totaux P et N ; « 16.917 » se lit seize mille neuf cent dix-sept.
3. Pour le seuil : TP et FP = effectifs du côté « positif » ; colonnes souvent cumulées.
4. $FN=P-TP$, $TN=N-FP$; contrôle $TP+FN+FP+TN=$ total.
5. Sensibilité, spécificité ; inverser la classe positive les échange.

Série 2 ex. 1. 23 417 produits, 16 917 bons, 6 500 défectueux ; au-dessus de 18 : 15 863 bons, 697 défectueux. Positif = défectueux : $TP=5\,803$, $FN=697$, $TN=15\,863$, $FP=1\,054$; sensibilité 0,893, spécificité 0,938 (inversées si positif = bon). **PZH 2020.** 4 M habitants, 5 % infectés, TPR 0,85, TNR 0,96 : 170 000 vrais signalés, 152 000 faux, 322 000 signalés dont 47,2 % sains ; précision 0,528. **ENT 2021.** Seuil 30 absent du tableau : encadrer entre les colonnes 25 et 50 ; seuil où tous sont positifs : TPR 1, TNR 0. **Cours 3** (20 000 patients, malade si $x\geq12$) : sensibilité 0,8, spécificité 0,55, accuracy 0,675, précision 0,64, $F_1=0{,}711$.

ROC : TPR en fonction de FPR quand le seuil varie. Seuil qui déclare tout positif : $(1,1)$; aucun : $(0,0)$. Hasard ou attribut sans rapport : diagonale, AUC = 0,5 (quiz 03.6) ; idéal 1 ; $<0{,}5$ pire que le hasard. Trapèzes (cours : 0,754) :

$$\text{AUC}\approx\sum_i\frac{(\text{FPR}_{i+1}-\text{FPR}_i)(\text{TPR}_i+\text{TPR}_{i+1})}{2}$$

Coquilles des slides du cours 3. p. 38 : TN sur la case malade-malade (lire TP) ; p. 40 : dénominateur de l'accuracy $TP+FN+FP+FN$ (lire $+TN$) ; p. 39 : $(1-y_i)(1-\log(1-p))$ (lire $(1-y_i)\log(1-p)$) ; p. 49 : AUC « should be $<0{,}5$ » (lire $>0{,}5$, comme p. 50). Multiclasse : sensibilité d'une classe sur sa ligne, précision sur sa colonne. Classes déséquilibrées : toujours prédire la majorité donne une forte accuracy et une sensibilité nulle.

5. K-means

1. Choisir K, initialiser les centres.
2. Affectation : tableau des d^2 de chaque point à chaque centre (la racine est inutile).
3. Mise à jour : centre = moyenne, coordonnée par coordonnée, des points affectés.
4. Répéter jusqu'à aucun changement d'affectation ou J itérations. Chercher les symétries.

Coût $O(NKJd)$, dont NKd à chaque itération. Dépend de l'initialisation ; K fixé d'avance ; clusters supposés sphériques et de tailles voisines ; optimum local.

Série 1 ex. 4 ($c_1=[5;-1]$, $c_2=[5;4]$) : groupe 1 [5; 1], [4; −3], [4; 0], [7; −1] ; groupe 2 [5; 2], [6; 2], [7; 7], [2; 3] ; $c_1=[5;-0{,}75]$, $c_2=[5;3{,}5]$. **EX 2022** ($c_1=[0;0]$, $c_2=[6;10]$) : seuls P2 et P9 vont à c_2 ; les huit autres sont symétriques autour de l'origine : $c_1=[0;0]$, $c_2=[6;11]$.

Quiz 04.2 (raté), sens du déplacement : refaire l'affectation avec les centres actuels, puis déplacement = moyenne du groupe − ancien centre. Ne pas deviner à l'œil.

Yinyang (inégalité triangulaire) : $ub'=ub+d(b,b')$, $lb'=lb-d(c_k,c_k')$; si $ub'<lb'$, ne pas calculer $d(x,c_k')$.

6. Activations, vanishing gradient (série 1 ex. 3)

	$f(s)$	$f(0)$	bornes	f'
sigmoïde	$1/(1+e^{-s})$	0,5	$]0;1[$	$y(1-y)$, max 0,25 en 0
tanh	$\frac{e^s-e^{-s}}{e^s+e^{-s}}$	0	$]-1;1[$	$1-y^2$, max 1 en 0
ReLU	$\max(0,s)$	0	$[0;+\infty[$	0 si $s<0$, 1 si $s>0$
seuil	1 si $s\geq0$, sinon 0			nulle, non dérivable en 0

Tracé : $\sigma(\pm2)=0{,}88$ et 0,12 ; $\tanh(\pm1)=\pm0{,}76$, $\tanh(\pm2)=\pm0{,}96$; ReLU par $(1;1)$, $(2;2)$, pentes 0 et 1 notées, axes nommés. $\sigma'(0)=0{,}25$, $\sigma'(2)=0{,}105$, $\sigma'(5)=0{,}0066$. Logistique de pente a : $f'=a\,y(1-y)$.

Vanishing gradient, réponse type. Le gradient d'une couche est le produit des dérivées des couches suivantes. Dérivées <1 : le produit tend vers 0 avec la profondeur, les premières couches n'apprennent presque plus. Sigmoïde et tanh saturent ($f'\approx0$ pour $|s|$ grand) ; $\sigma'\leq0{,}25$, donc au plus $0{,}25^4=0{,}0039$ sur 4 couches, $0{,}25^5\approx0{,}001$ sur 5. ReLU peu touchée (dérivée 1 pour $s>0$), mais neurone mort pour $s<0$ (dying ReLU). TP NN4a : « paralysie du réseau » (sigmoïdes et très grands poids, slide 33) ; Rprop n'utilise que le signe de la dérivée (slide 37). La rétropropagation exige une activation dérivable.

7. Clustering hiérarchique (série 2 ex. 2)

Ascendant : N clusters au départ, fusion des deux plus proches à chaque étape. Dendrogramme : hauteur d'une fusion = sa distance. **Nombre de clusters à une distance donnée** : tracer l'horizontale, compter les traits verticaux coupés. Distance limite : points restés seuls = anomalies.

single (minimum)	$\min\{d(a,b) : a \in A, b \in B\}$
complete (maximum)	$\max\{d(a,b) : a \in A, b \in B\}$
average	$\sum_a \sum_b d(a,b) / (\lvert A\rvert \lvert B\rvert)$
centroïde	$\lVert c_A - c_B\rVert$

Série 2 ex. 2 : **6 clusters** à 2,5 (dernière fusion sous la coupe vers 2,2, suivante vers 2,7) ; 4 à 3,0 ; 8 à 2,0 (lecture limite). Feuille sans étiquette à côté de p_8 : sans effet. Points $0, 1, 3, 7, 12, 13{,}5$: single donne $\{a,b,c,d\}, \{e,f\}$; complete donne $\{a,b,c\}, \{d,e,f\}$: les critères peuvent différer (quiz 04.3, 04.4). **Coquille** cours 4 p. 27 : « $d_{S13} < d_{S12}$ » pour le maximum, lire $d_{M13} < d_{M12}$. Pas de K à fixer ; une fusion ne se défait pas ; $O(n^3)$ en force brute, $O(n^2 \log n)$ en single linkage. Descendant (divisif) : plus coûteux. DBSCAN : ε, MinPts ; point cœur, frontière, bruit ; formes quelconques ; $O(n^2)$; densités variables mal gérées.

8. Distances, kNN, complexité

euclidienne	$\sqrt{\sum_i (x_i - y_i)^2}$; la grande amplitude domine
Manhattan	$\sum_i \lvert x_i - y_i\rvert$; aucune multiplication
Minkowski	$(\sum_i \lvert x_i - y_i\rvert^p)^{1/p}$; $p = 2$, $p = 1$
cosinus	$A \cdot B / (\lVert A\rVert \, \lVert B\rVert)$ (texte)
Hamming	positions qui diffèrent (binaire, catégoriel)
Mahalanobis	$\sqrt{(\mathbf{x}-\boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{x}-\boldsymbol{\mu})}$; $\boldsymbol{\Sigma}$ diagonale : $\sqrt{\sum_i (x_i - y_i)^2 / \sigma_i^2}$

Masse 40 à 150 kg, pH 7,34 à 7,45 (cours 4 p. 7) : l'euclidienne choisit P_2 (4,90 contre 5), Mahalanobis P_1 (0,157 contre 1,739) ; loi uniforme, $\sigma = (b-a)/\sqrt{12}$. Quiz 04.1 : échelles très différentes, Mahalanobis ou mise à l'échelle.

kNN : K plus proches, vote majoritaire ; pas d'entraînement, tout le coût à chaque classement : $O(dN)$ par point. d^2 : Nd multiplications, Nd soustractions, $N(d-1)$ additions ($N = 2000$, $d = 10$: 20 000) ; racine inutile ; choix des K : comparaisons. Sur M nœuds : K meilleurs parmi MK, total inchangé, temps divisé par M. K-means $NKdJ$: $2000 \times 7 \times 10 \times 20 = 2{,}8 \cdot 10^6$. Lire le quiz 03.1 mot à mot (multiplications seules ? racine ?).

O : $T(N) = O(F(N))$ s'il existe c, N_0 avec $T(N) \le c\,F(N)$ pour $N > N_0$. $O(1) < O(\log N) < O(N) < O(N \log N) < O(N^2)$. Pièces : force brute $N-1$ pesées, moitiés $\lceil \log_2 N \rceil$, tiers $\lceil \log_3 N \rceil$. Tris : quick et merge $O(N \log N)$ en moyenne (quick $O(N^2)$ au pire), bulles $O(N^2)$ et mémoire $O(1)$; mémoire du quicksort : la slide donne $O(N \log N)$, répondre avec la slide. Dimension : cases 20^{dim}.

9. Généralisation, surapprentissage, données

- Surapprentissage : modèle trop complexe qui apprend le bruit ; erreur d'entraînement qui baisse, erreur de validation qui remonte. EX 2020-2 Q6 : E5 sépare le test sans erreur, EV fait des erreurs sur le test.
- Validation : arrêt, hyperparamètres. Test : une fois, à la fin. Choisir sur le test rend l'erreur annoncée trop optimiste.
- Découpage 60 : 20 : 20 (NN2a) ; 70 : 15 : 15 (cours 5). Chaque jeu reproduit la répartition réelle (exemple 20-20-60 du cours 3).
- **Early stopping** : arrêt à la première hausse de l'erreur de validation. **Backtracking** (recommandé) : entraîner, sauvegarder chaque époque, revenir au minimum de validation. Série 0,40 ; 0,31 ; 0,26 ; 0,24 ; 0,25 ; 0,23 : époque 4 contre époque 6.
- Plus de neurones cachés : erreur d'entraînement toujours plus basse, erreur de test en U. Plus d'exemples : meilleure généralisation.
- Bruit sur les entrées (jitter) : moins de surapprentissage ; sur les cibles : ralentit seulement.
- Remèdes : petit réseau, beaucoup de données, early stopping, régularisation $\gamma\,\text{mse} + (1-\gamma)\,\text{msw}$.
- Moment : $\Delta w(n) = \alpha\,\Delta w(n-1) + \eta\,\delta\,y$. Séquentiel (après chaque exemple, préféré) ou par lot (après chaque époque).
- Supervisé (étiquettes : kNN, arbres) ; non supervisé (k-means, hiérarchique) ; par renforcement (récompense différée).

10. PCA

1. Centrer chaque colonne.
2. $\boldsymbol{\Sigma} = \frac{1}{N} \mathbf{X}_{(st)}^\top \mathbf{X}_{(st)}$.
3. Valeurs propres : $\lambda^2 - \operatorname{tr}\lambda + \det = 0$ en 2×2 ; vecteur propre unitaire.
4. Variance décrite $\sum_{i \le r} \lambda_i / \sum_i \lambda_i$.
5. Projeter sur $\mathbf{u}_1, \ldots, \mathbf{u}_r$.

Points $(7,5), (1,-1), (5,1), (3,3)$: moyenne $(4,2)$, $\Sigma = \begin{pmatrix} 5 & 4 \\ 4 & 5 \end{pmatrix}$, $\lambda = 9$ et 1, $\mathbf{u}_1 = (1,1)/\sqrt{2}$, 90 %, projections $\pm 4{,}243$, 0, 0. SVD : $\lambda_i = s_i^2/N$. Linéaire seulement ; nouvelles variables difficiles à interpréter. TP 3 : `pca_cancer.m` ne centre pas.

11. Cas d'usage : détection de chute (cours 5)

Accéléromètre 3 axes, 62,5 Hz ; normalisation $x_{nk} = \frac{x_k - \text{mean}}{\text{std}}$ (std divisée par N) ; fenêtres de 2 s qui se recouvrent (125 échantillons par axe) ; caractéristiques (norme $\sqrt{a_x^2 + a_y^2 + a_z^2}$, G-force $\lvert a\rvert/9{,}8$, inclinaison, vitesse, écart-type, skewness, kurtosis, durées) ; petit réseau TinyML à trois classes. 3600 essais, 70 : 15 : 15 (2520, 540, 540). Test 561 fenêtres : accuracy float32 555/561 = 0,989, int8 552/561 = 0,984 ; aucune chute manquée ; int8 divise la mémoire des poids par 4. Anomalie : k-means sur 9 caractéristiques, $d(\mathbf{x}) = \min_k(\lVert \mathbf{x} - c_k\rVert_2 - r_k)$, négatif ou nul : normal ; au-dessus du seuil : anomalie.

12. Cours 1 et 2 : repères

Embarqué : une tâche, ressources limitées (mémoire, calcul, temps de réponse, énergie), interface minimale, durée de vie de dix ans ou plus. EdgeAI : latence, confidentialité, bande passante, fonctionne sans connexion. On n'entraîne généralement pas sur l'embarqué (ResNet152 : 1,5 semaine). Énergie (pJ, 45 nm) : addition 32 bits 0,1 ; addition FP32 0,9 ; multiplication FP32 3,7 ; multiplication 8 bits 0,2 ; SRAM 5 ; DRAM 640 (environ 1000 opérations). DRAM : $P = \frac{1}{2} \sum C_i V_i^2 f_i$. FP32 $(1, 8, 23)$, FP16 $(1, 5, 10)$, int8 de 0 à 127. **Coquille** : la slide donne $6 \cdot 10^4$ pour Int16, alors que $2^{15} - 1 = 32\,767$. Taille = paramètres × octets (4, 2, 1) : VGG16, 134,2 M, 512 Mo en FP32. Cerveau : 1,3 kg, 20 W, 10^{10} neurones ; AlphaGo 1 MW = 50 000 cerveaux. Les huit défis : entraînement, taille, énergie, vitesse, encombrement, sûreté, confiance, gouvernance.